



# Managementsession AI

# Marco de Friend

> 20 Jahre IT-Branche

## CGI

- Executive Consultant
- Engagement Manager

## Themengebiete

- Testautomation
- IT Strategien
- Interimsmanagement



# Tobias Oberrauch

> 10 Jahre professionelle IT Erfahrung

## CGI

- Senior AI Consultant
- Leiter der CGI Workgroup AI



## KI-Bundesverband

- Stv. Regionalleiter Baden-Württemberg
- Leiter Taskforce Mittelstand
- Host von KI-Podcast

## AI Collaboration

- Initiator und Leitung der Initiative „AI Collaboration“.

# Agenda

01

**Einführung KI**  
Begriffserklärung  
Definitionen  
Projekt-Beispiel

02

**Praxisbeispiele**  
CGI  
Branche

03

**Vorgehensweise**  
AICF  
KI in großen  
Unternehmen  
implementieren

04

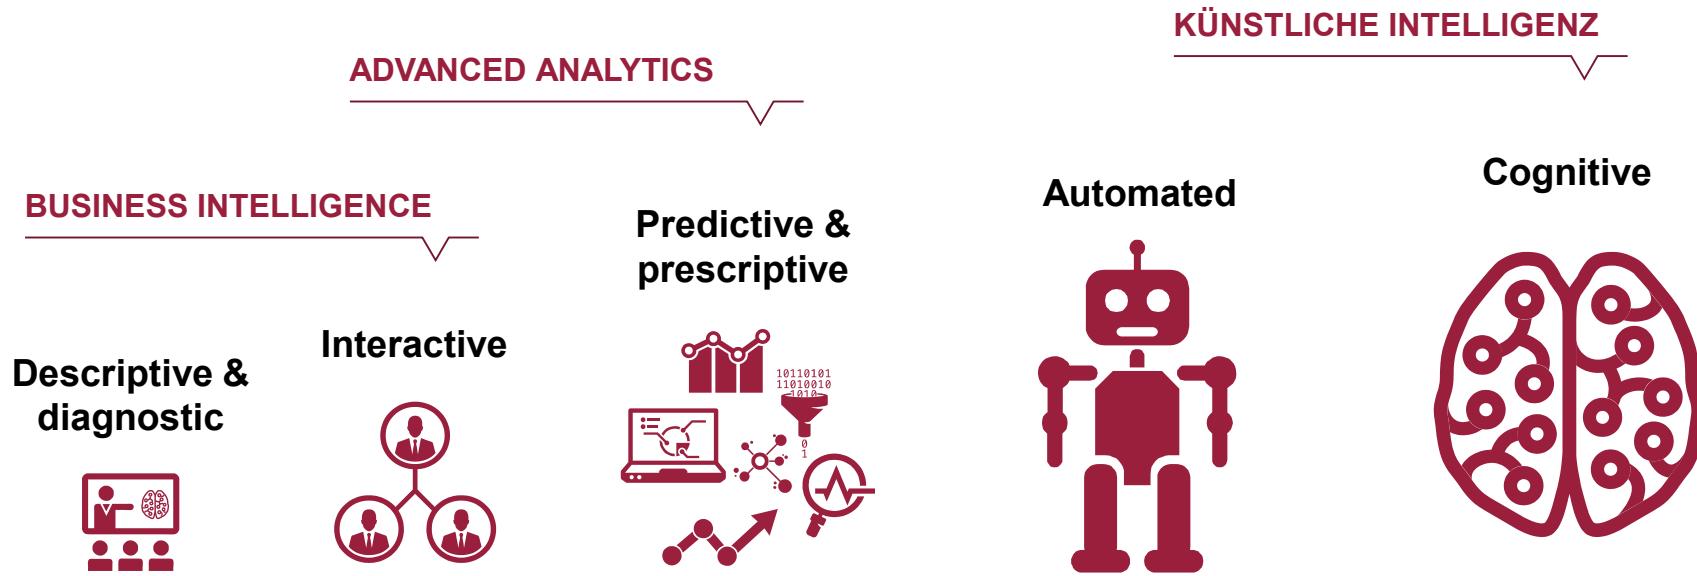
Beispiele aus  
der Praxis aus  
dem **Use Case**  
Catalog

05

Diskussion  
**Fragen**

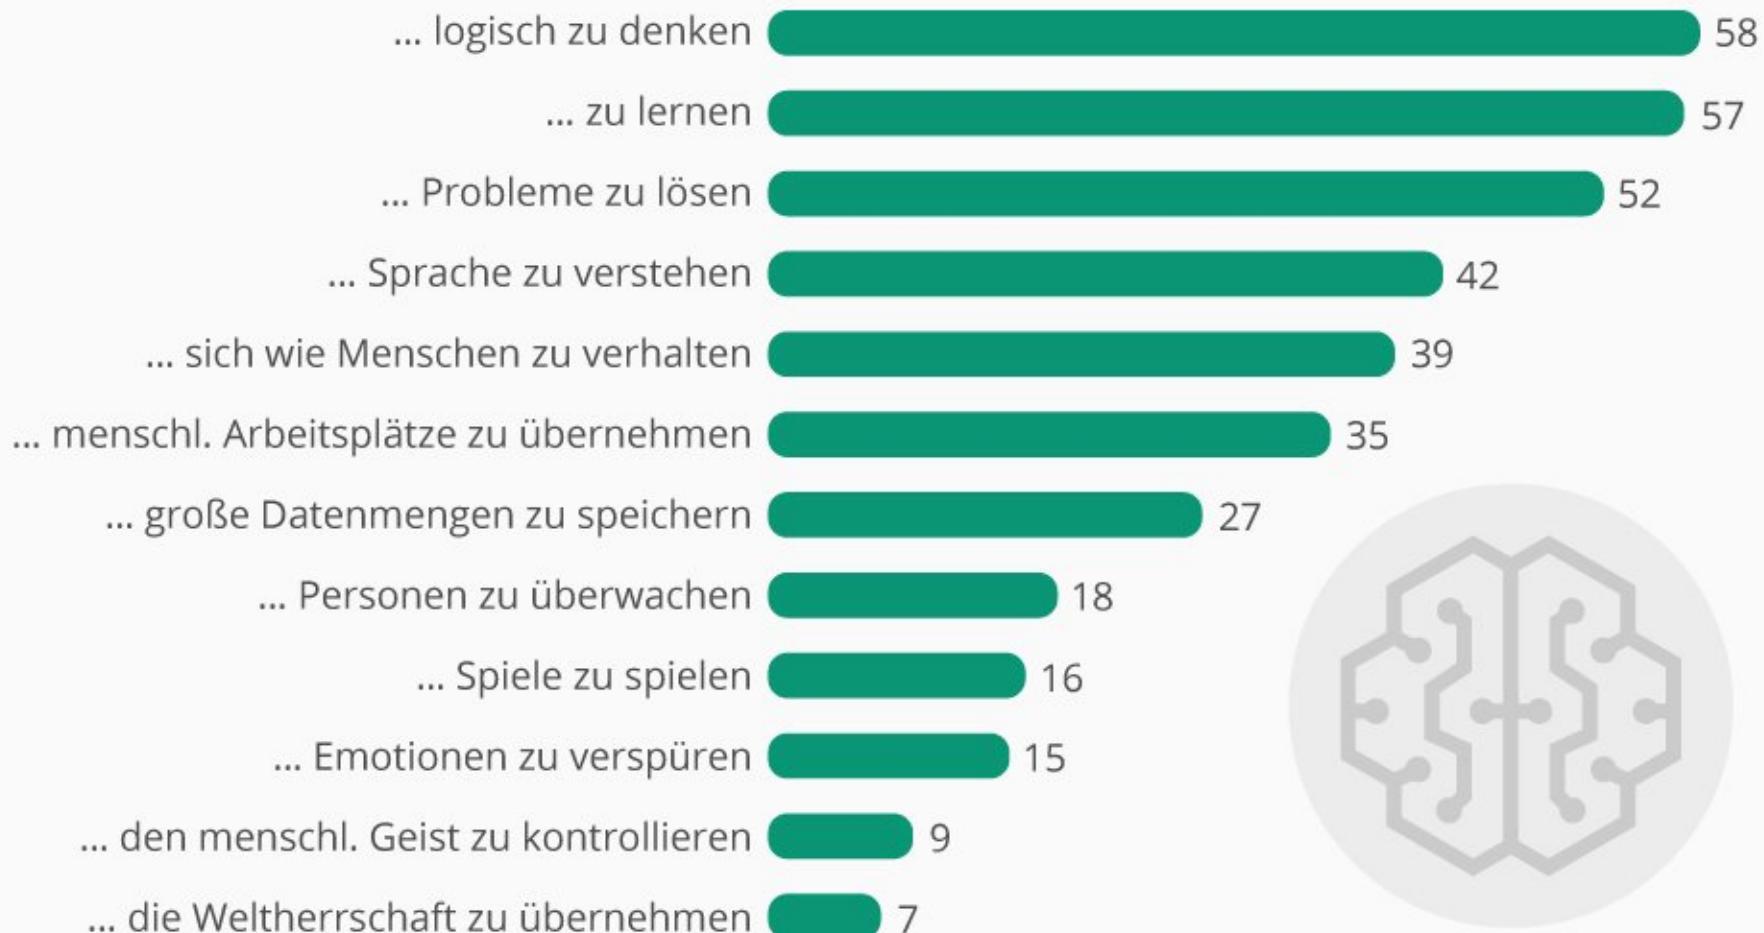
# Einführung KI

# Wertschöpfungsstufen bei Big Data Analytics



# Was ist künstliche Intelligenz?

Die Fähigkeit von Geräten und Software ...



*KI ist ein Teilgebiet der Informatik,  
dass sich mit der Automatisierung  
intelligenten Verhaltens und dem  
maschinellen Lernen befasst.*

*Wikipedia*

# Schwache und starke KI

## Starke KI

*Artificial General Intelligence*

Die Fähigkeit jede Aufgabe zu lösen oder zu erlernen, die ein Mensch kann.

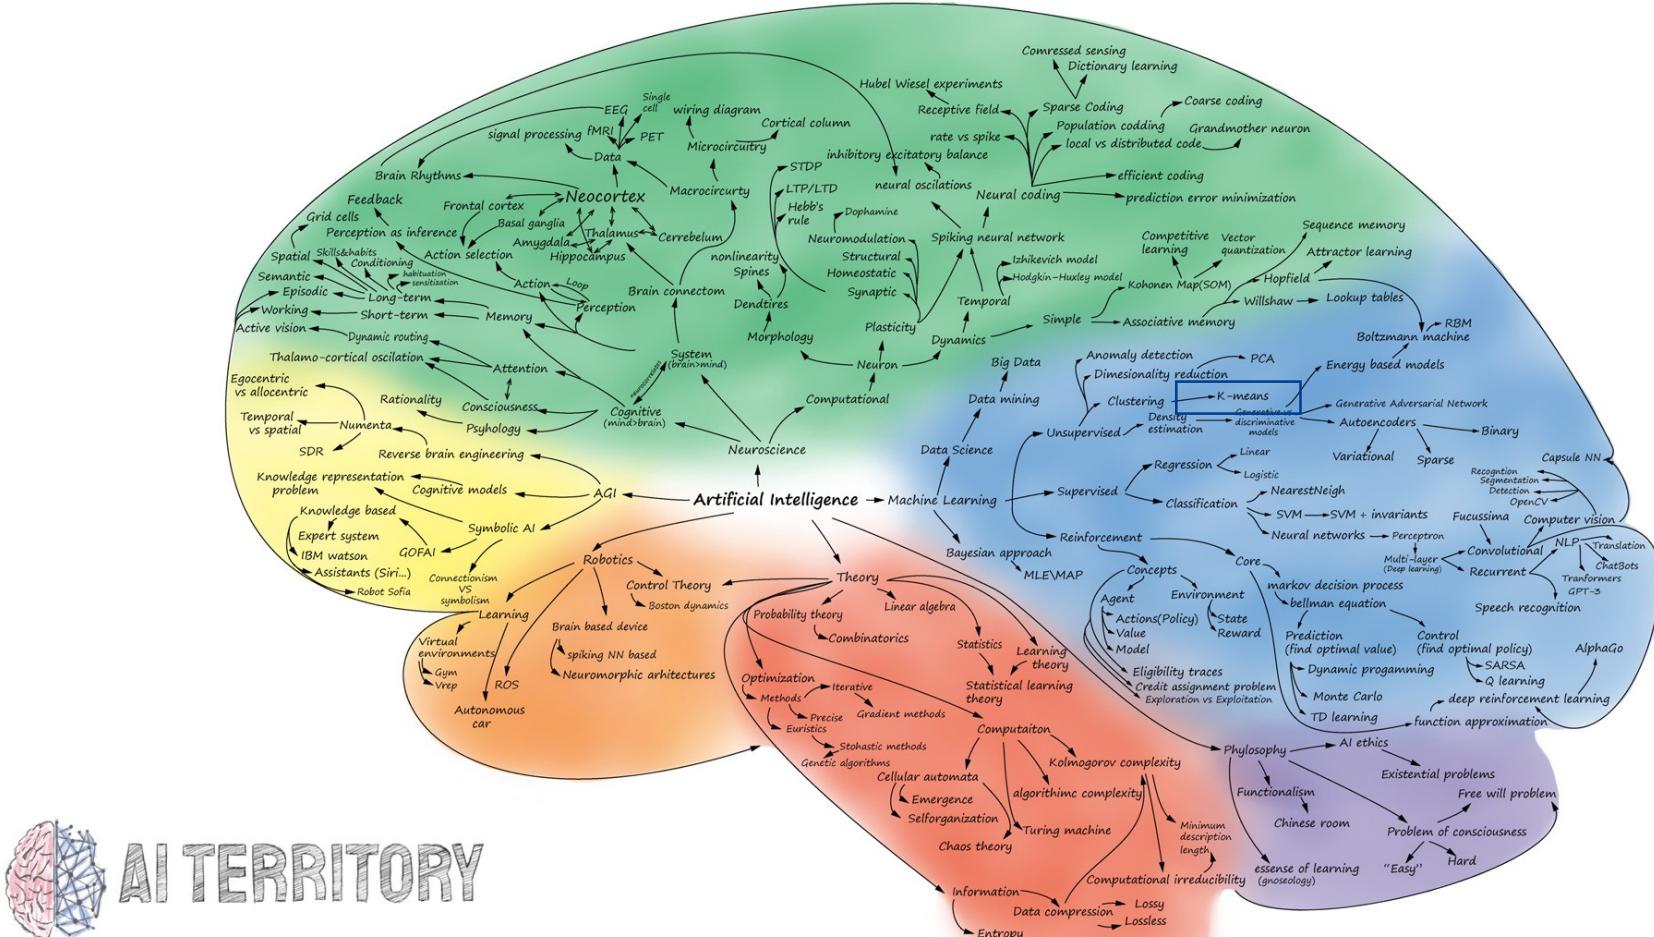
## schwache KI

*narrow AI*

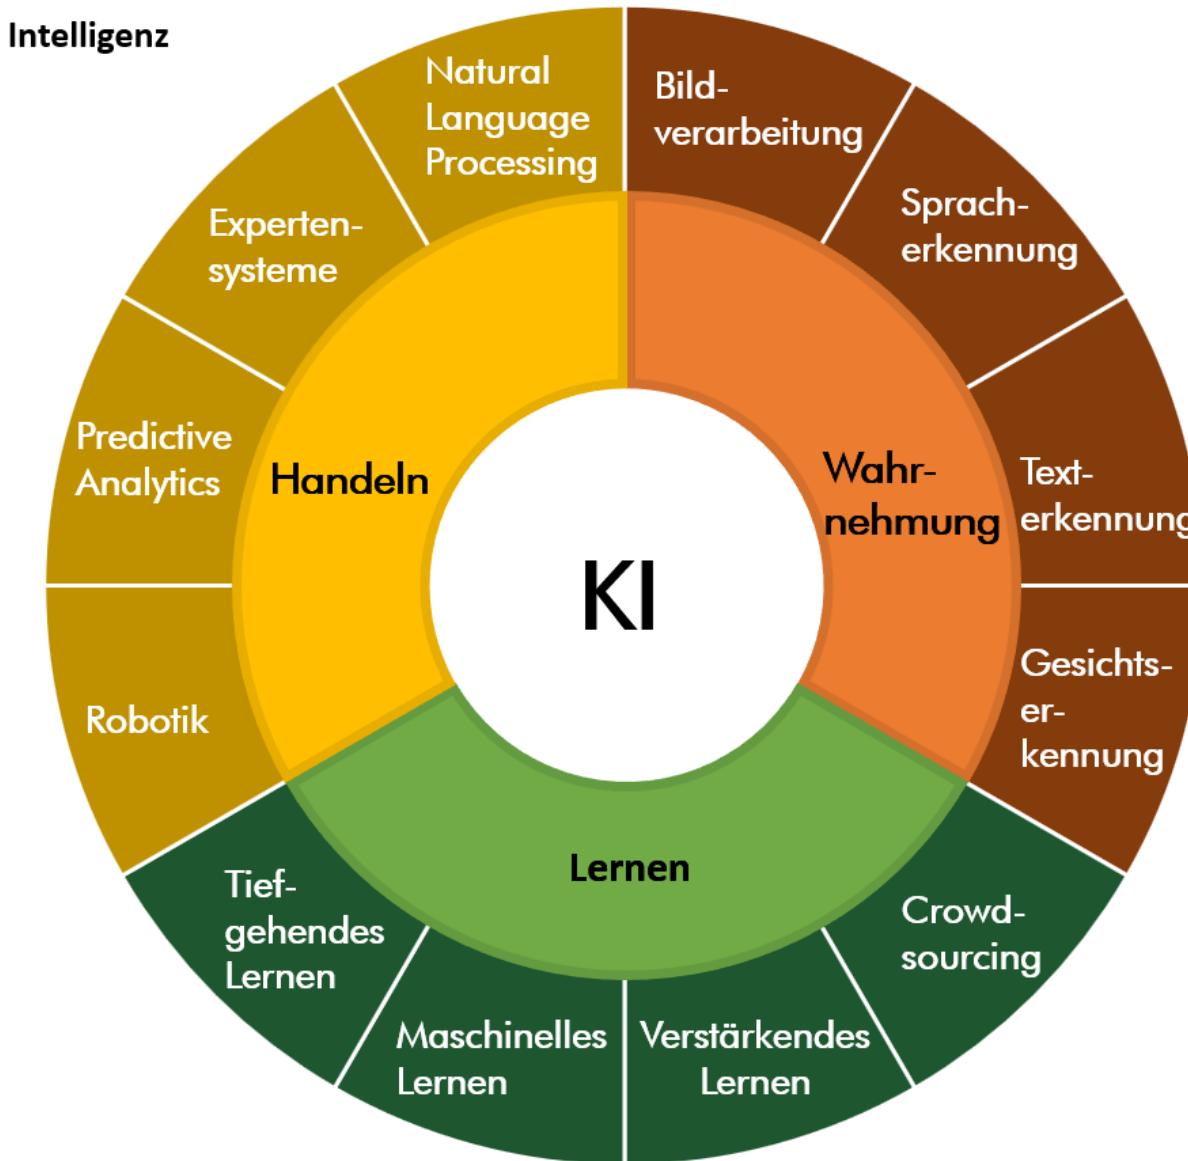
Die Fähigkeit eine spezielle Aufgabe sowie ein Problem zu lösen oder zu erlernen, die ein Mensch kann.

# Definitionen von KI

# Allgemeine Begriffsdefinition

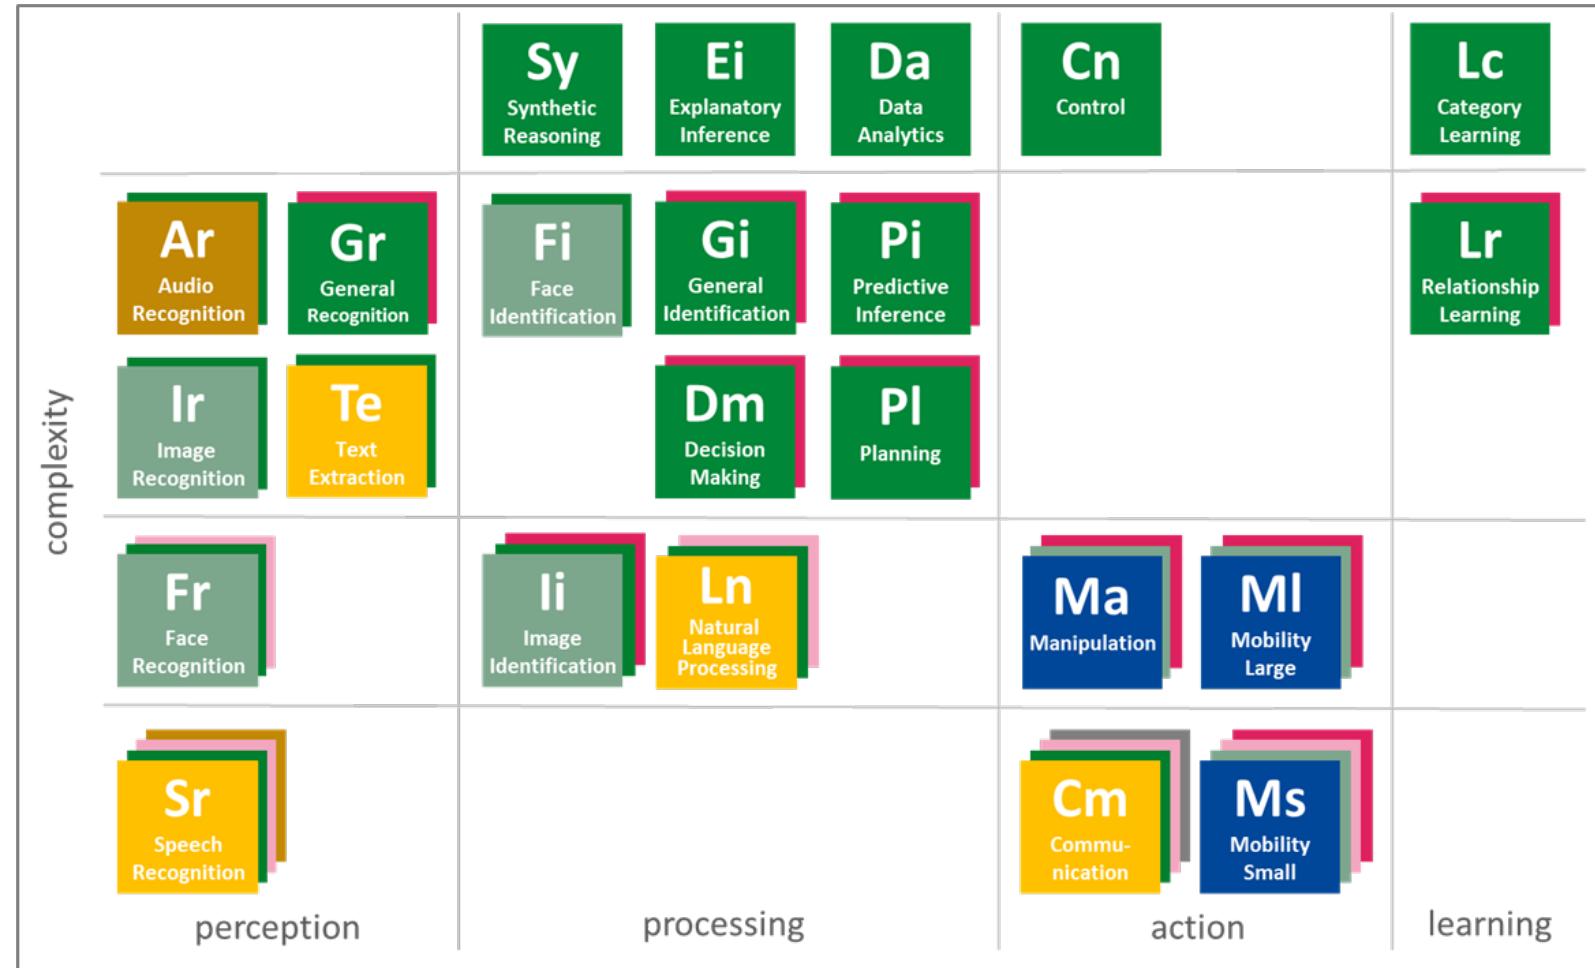


# Definition vom Institut für Marketing



logisch-mathematisch

# Definition von Universität St. Gallen



sprachlich-linguistisch

musikalisch

räumlich

körperlich-kinästhetisch

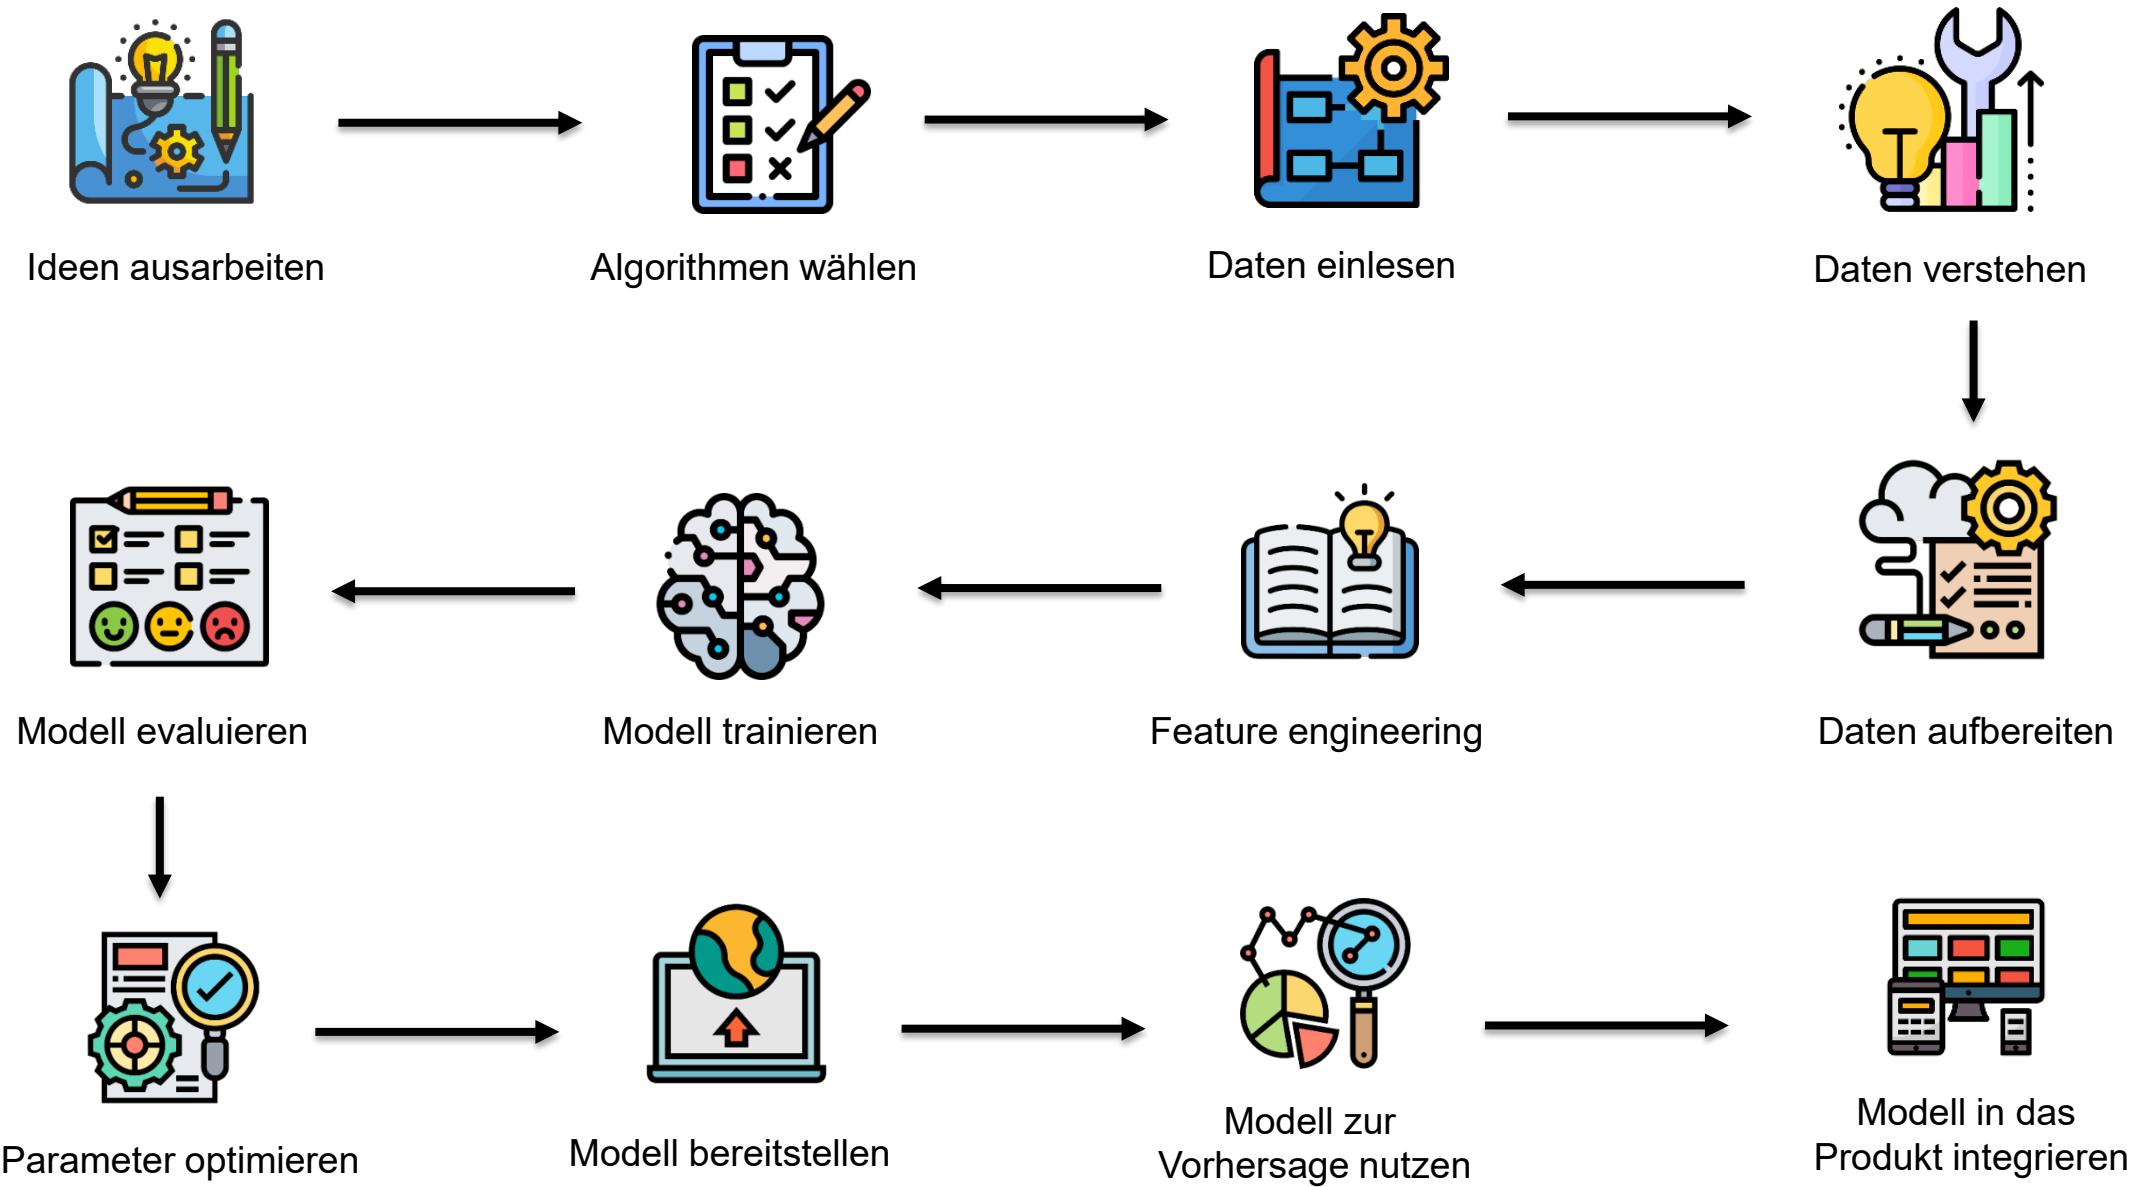
interpersonal

intrapersonell

naturalistisch

# Projekt „Anomaly detector“

**Beispiel mit Anomalieerkennung**



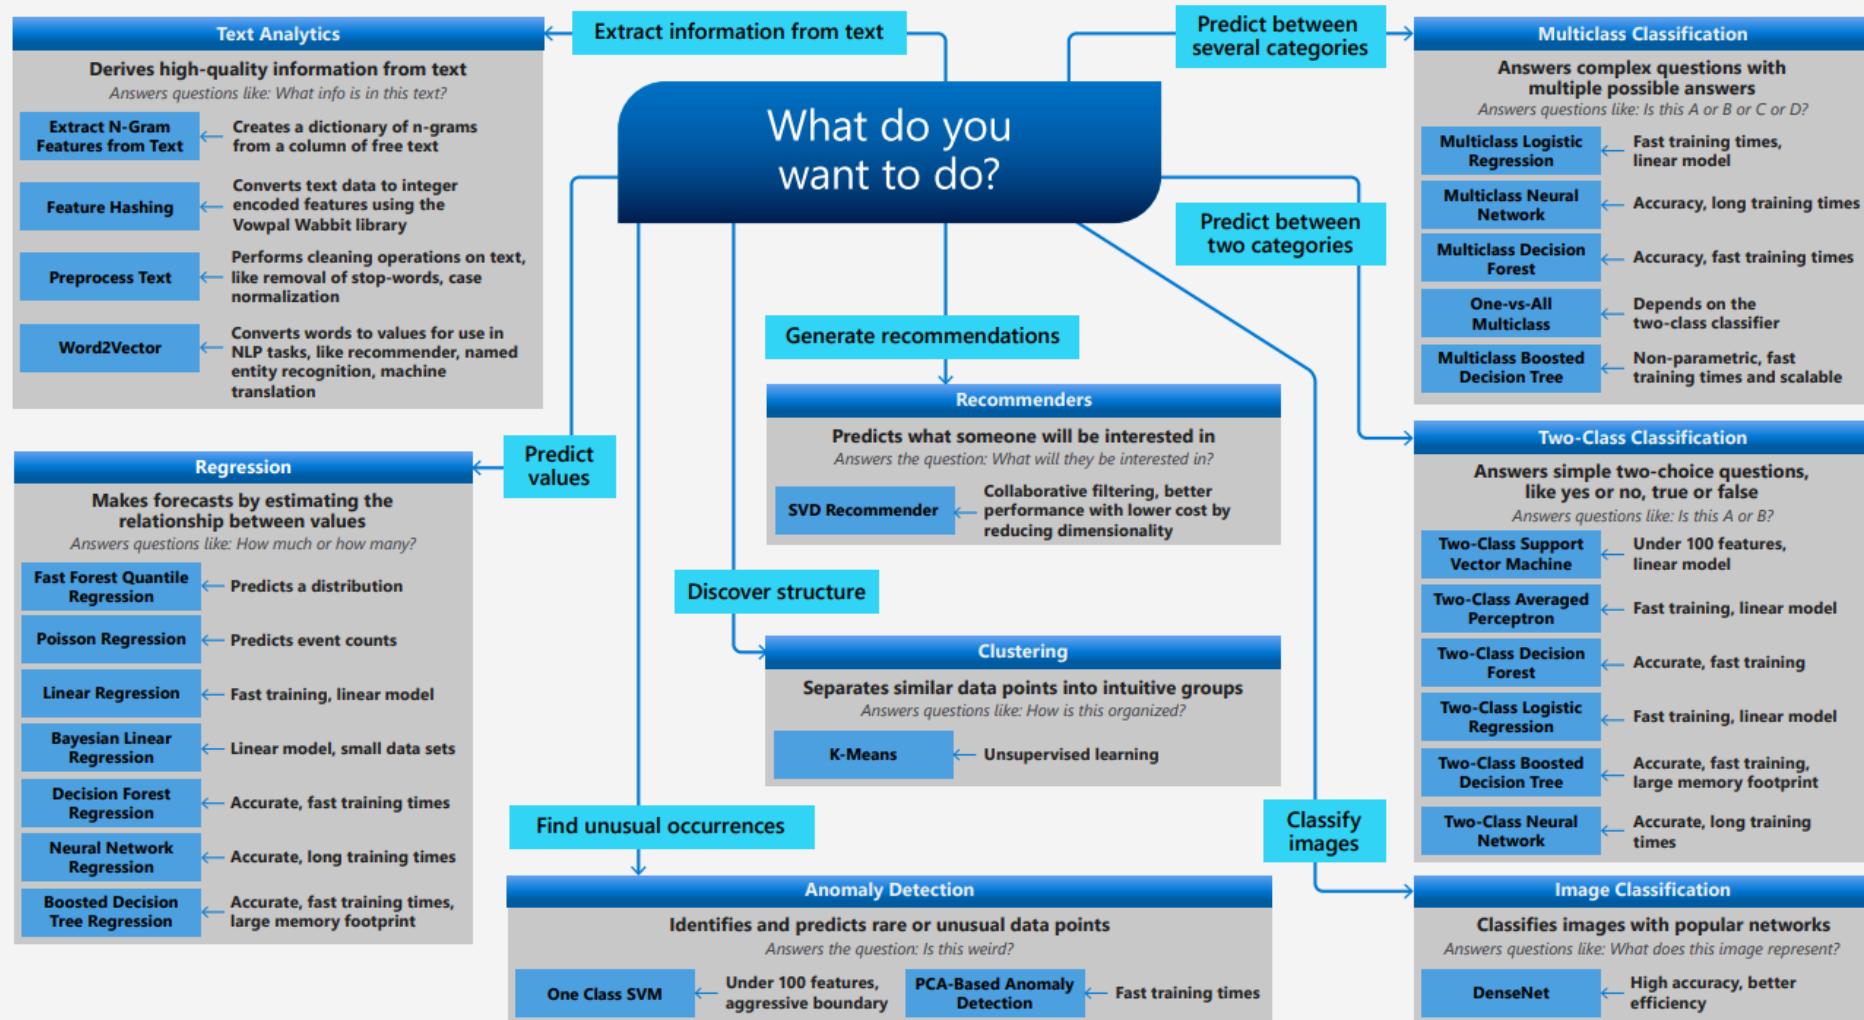


# Ideen ausarbeiten



Ideen ausarbeiten

# ML Canvas

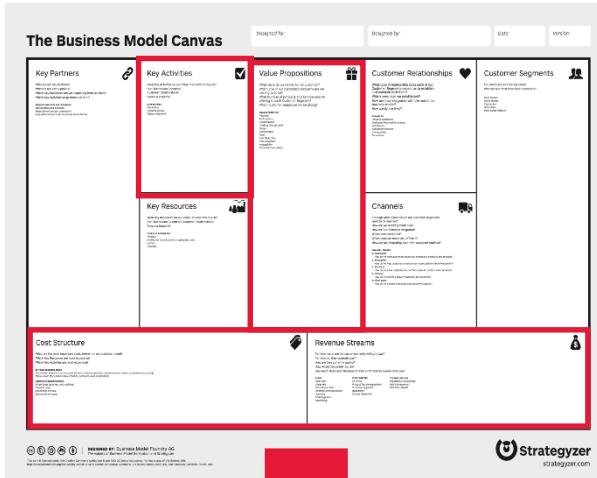


Internal

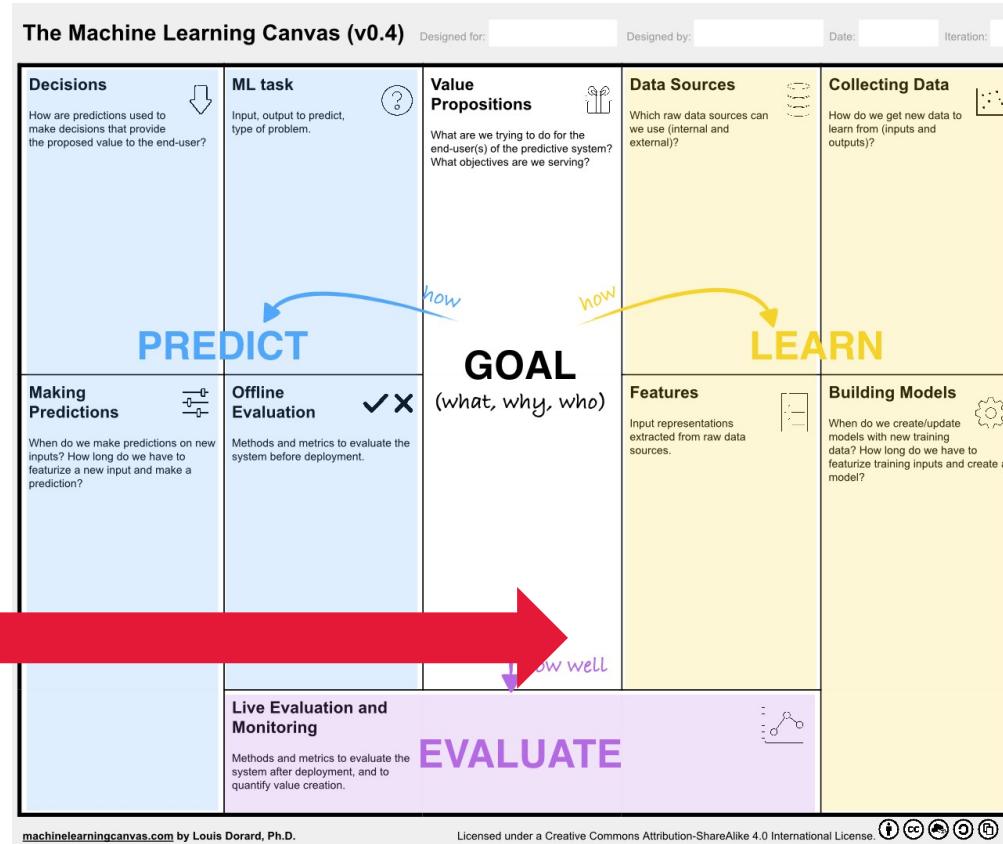


Ideen ausarbeiten

# ML Canvas



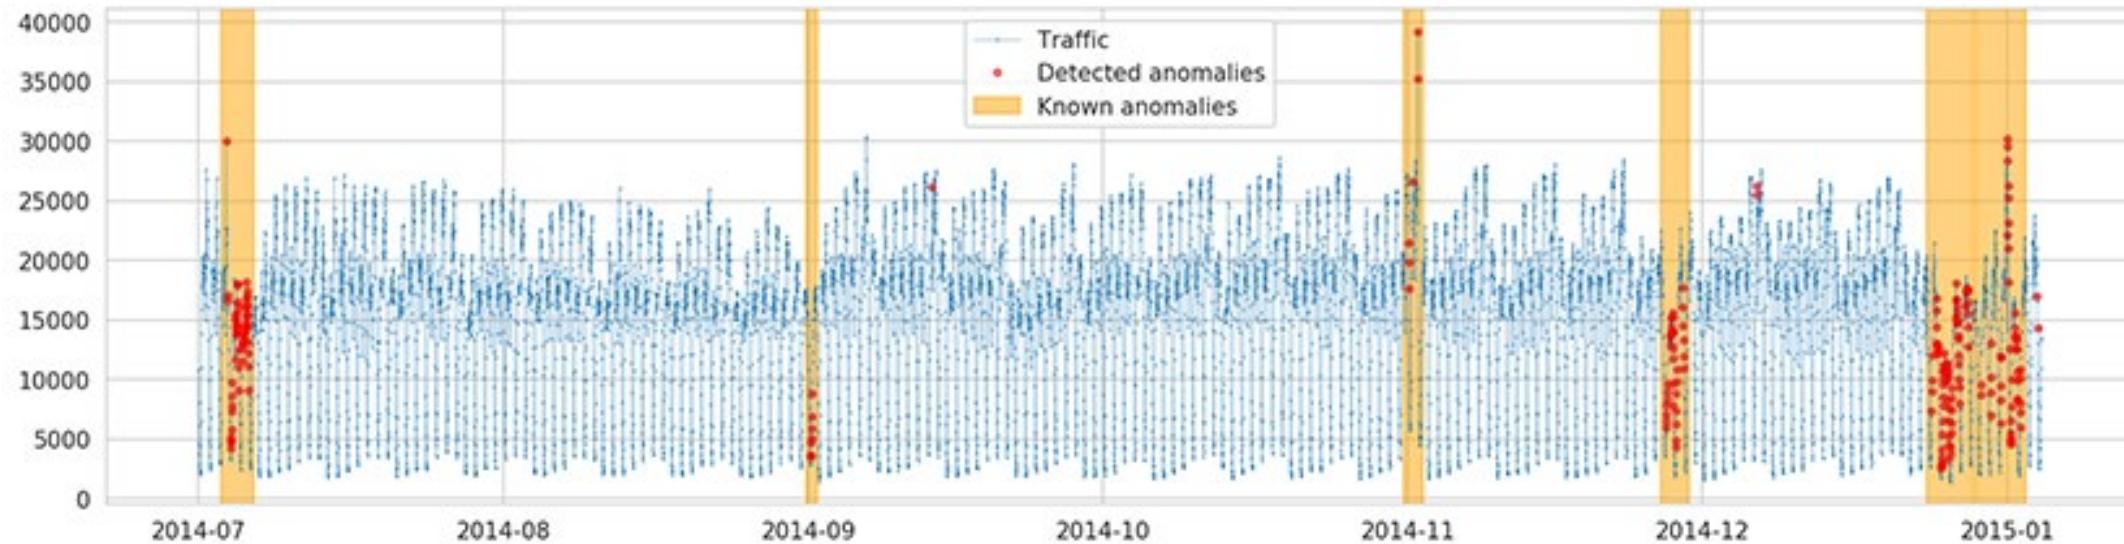
Business Capabilities  
Business Use Cases  
Value Proposition  
Business Goal





Ideen ausarbeiten

# Erkennen von Anomalien



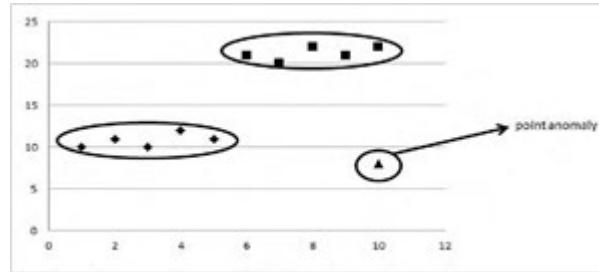


# Algorithmen identifizieren & auswählen



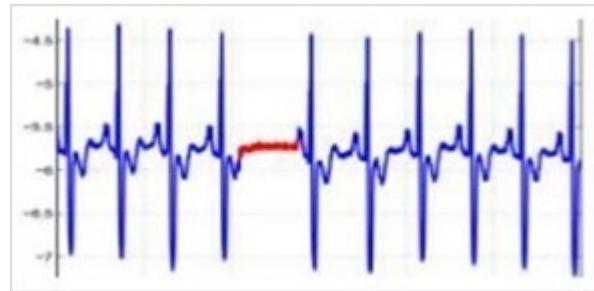
Algorithmen identifizieren & auswählen

# Arten von Anomalien



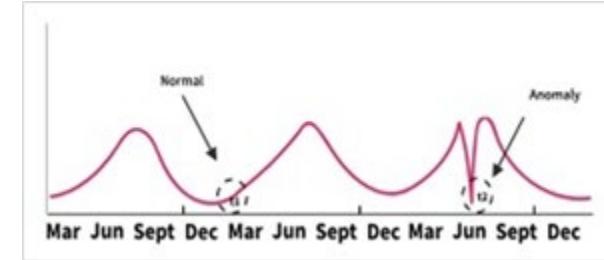
## Punktanomalie

Eine Dateninstanz, die unter anderen Instanzen im Datensatz anomali ist.



## Kollektive Anomalie

Eine Sammlung von zusammenhängenden Dateninstanzen, die im Bezug auf den gesamten Datensatz anomali sind.



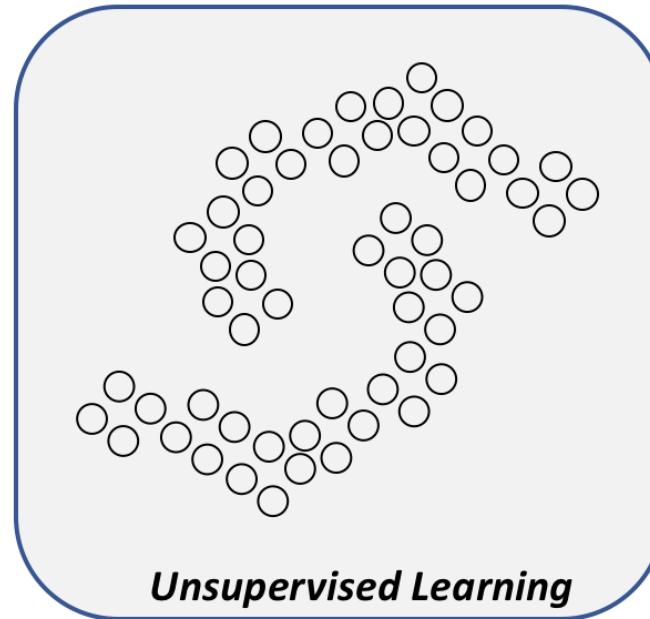
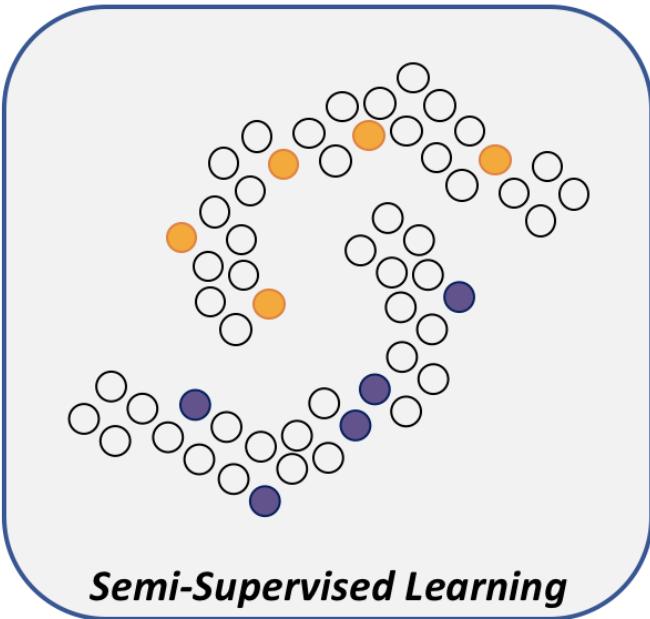
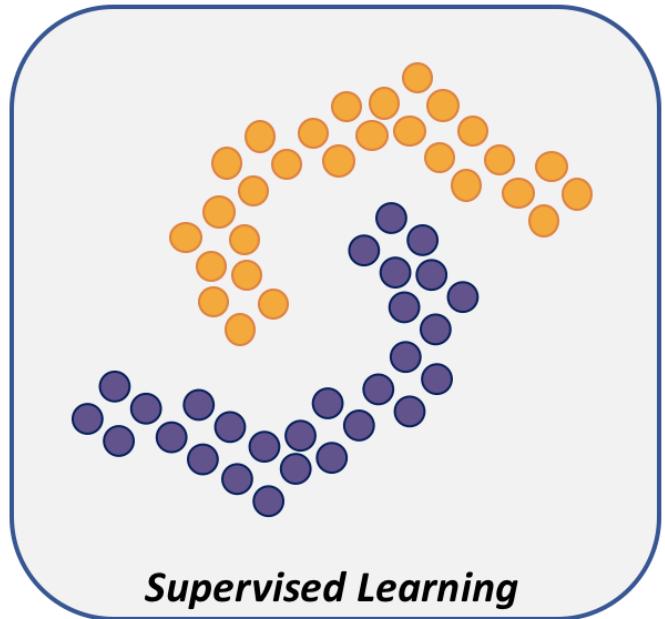
## Kontextuelle Anomalie

Eine Dateninstanz, die in einem bestimmten Kontext anomali ist



Algorithmen identifizieren & auswählen

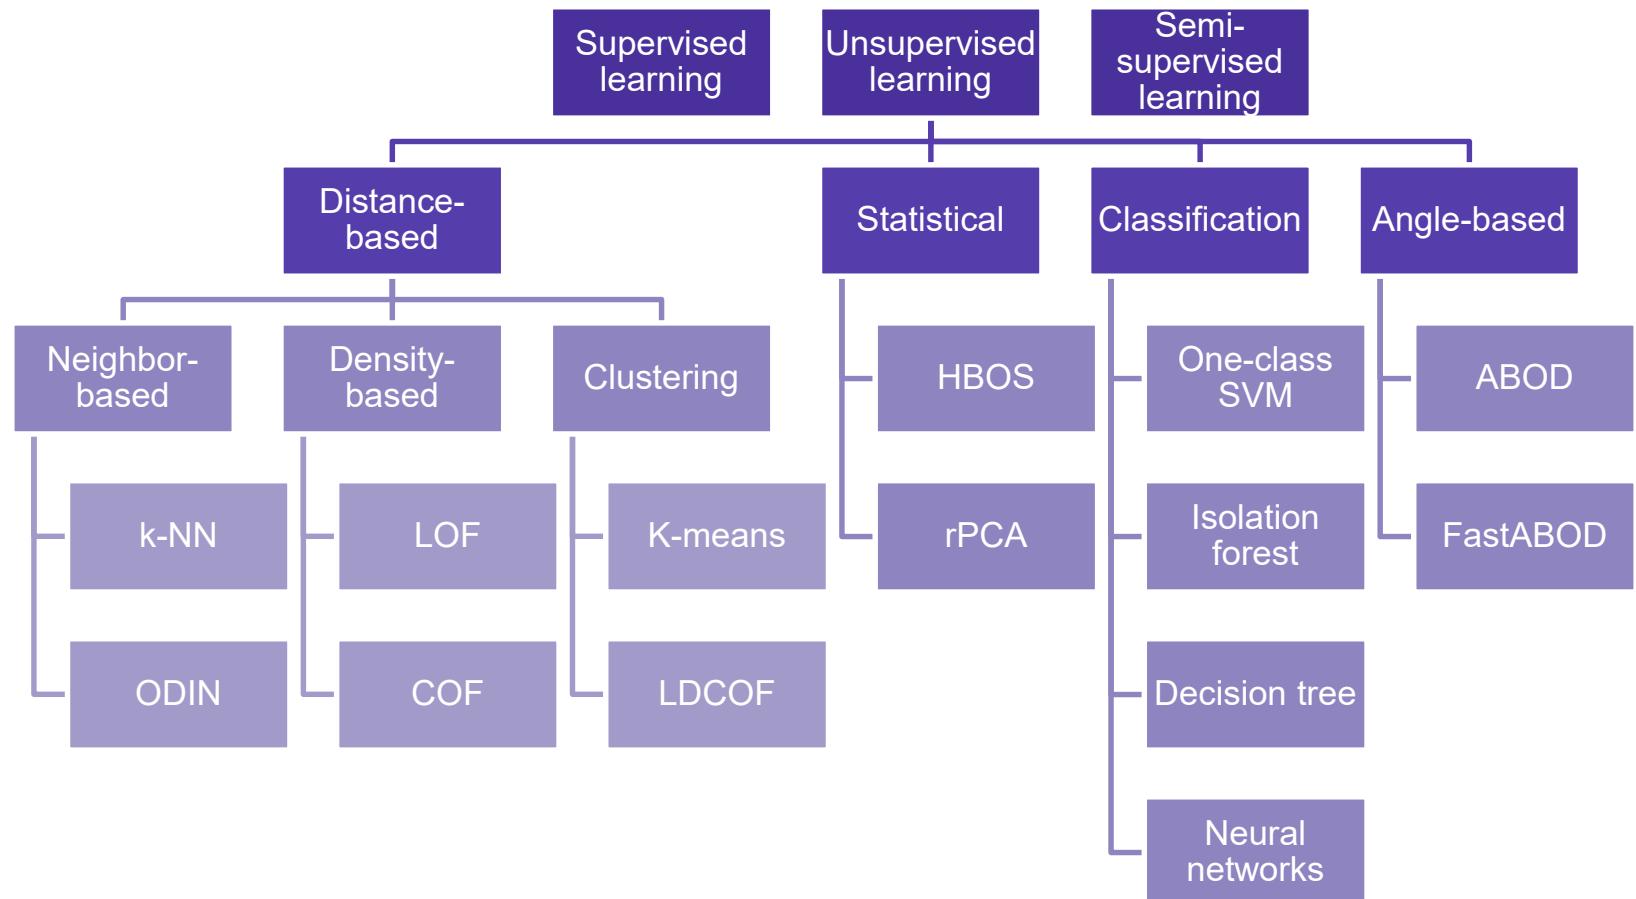
# Arten von Anomalien





Algorithmen identifizieren & auswählen

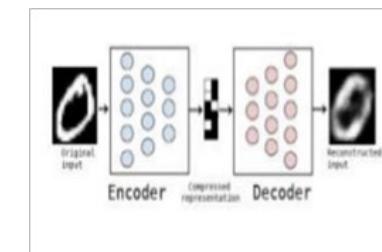
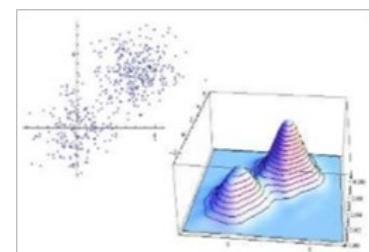
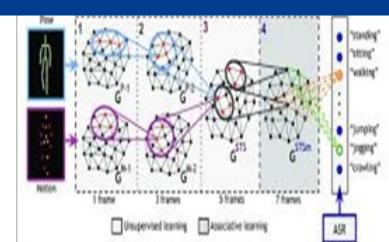
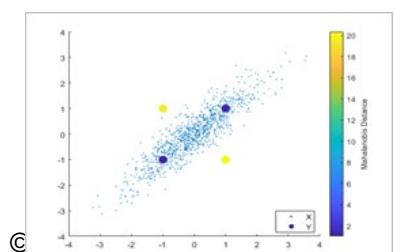
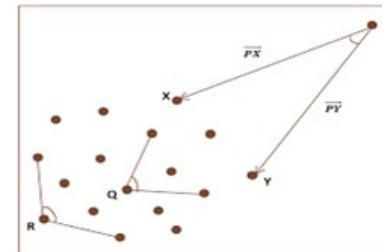
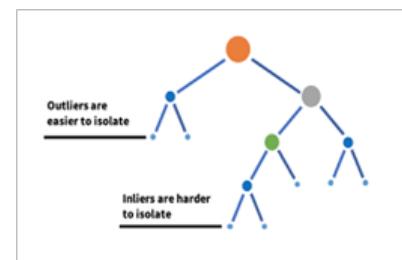
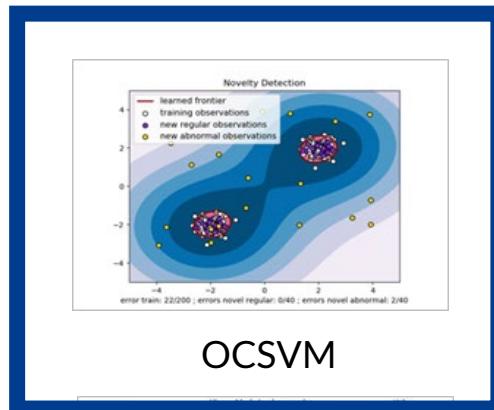
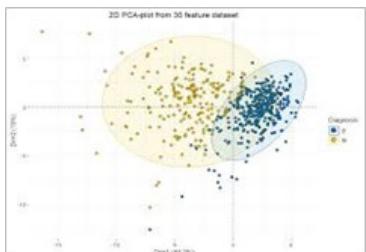
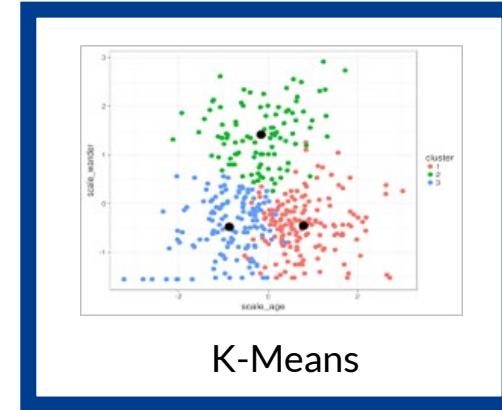
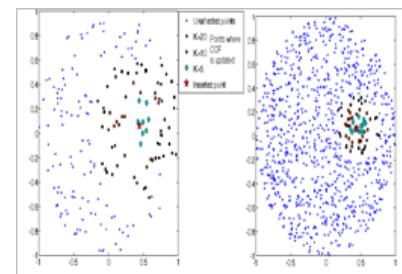
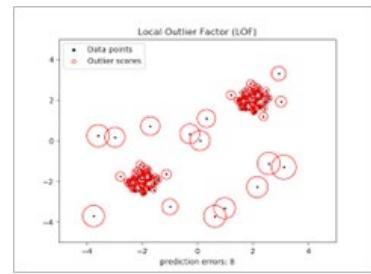
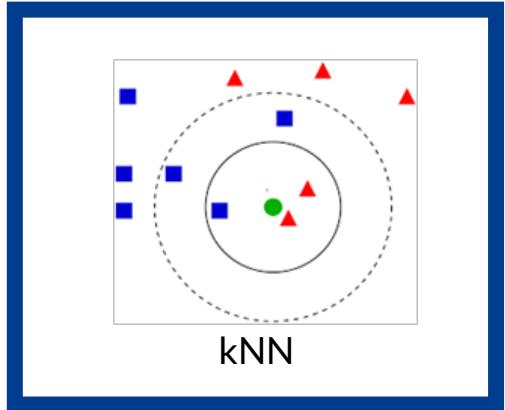
# Hierarchie





Algorithmen identifizieren & auswählen

# Arten von Algorithmen





Algorithmen identifizieren & auswählen

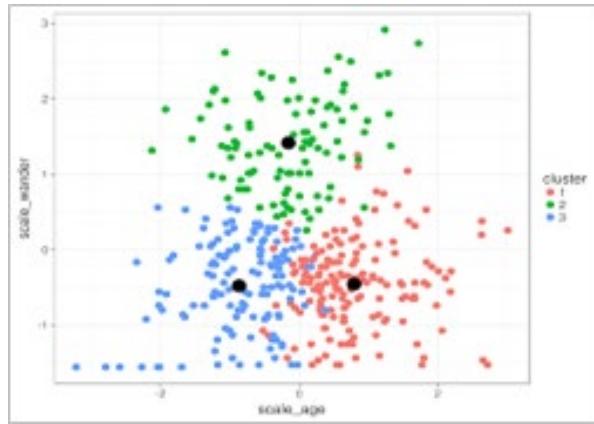
# Vergleich der Algorithmen

	K-Nearest neighbor	K-Means	Support vector machine
Vorteile	<ul style="list-style-type: none"><li>Einfach zu verstehen</li><li>Gut für Modelle mit unklaren Datenformaten</li></ul>	<ul style="list-style-type: none"><li>Geringe Komplexität</li><li>Einfach zu implementieren</li></ul>	<ul style="list-style-type: none"><li>Guter Umgang mit hochdimensionalen Daten und komplexen Strukturen</li></ul>
Nachteile	<ul style="list-style-type: none"><li>Rechenintensiv</li><li>Kann komplex bei Auswahl von Vergleichsoperator werden</li></ul>	<ul style="list-style-type: none"><li>Nur mit numerischen Daten</li></ul>	<ul style="list-style-type: none"><li>Erfordert viele Beispiele</li><li>In manchen Fällen instabil</li></ul>



Algorithmen identifizieren & auswählen

# K-means

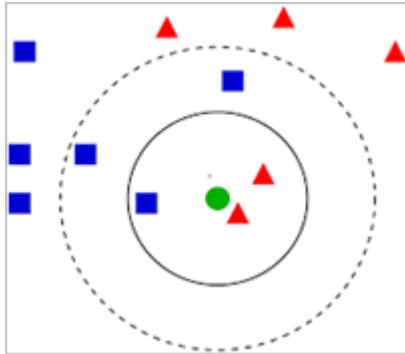


- Das K-Means-Clustering (MacQueen, 1967) ist eine Methode, die häufig verwendet wird, um einen Datensatz automatisch in  $k$  Gruppen zu partitionieren
- Jede Instanz wird dem nächstgelegenen Clusterzentrum zugewiesen. Jedes Clusterzentrum wird so aktualisiert, dass es den Mittelwert seiner konstituierenden Instanzen darstellt.

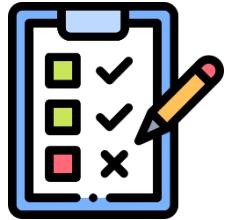


Algorithmen identifizieren & auswählen

# K-nearest neighbor

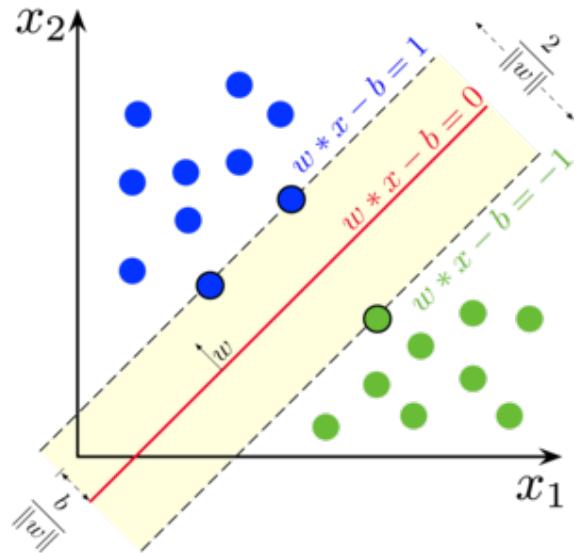


- k-nearest neighbors-Algorithmus (k-NN) ein nicht-parametrisches Klassifikationsverfahren, das erstmals 1951 von Evelyn Fix und Joseph Hodges entwickelt wurde.
- Bei der k-NN-Klassifikation ist die Ausgabe eine Klassenzugehörigkeit. Ein Objekt wird durch ein Pluralitätsvotum seiner Nachbarn klassifiziert, wobei das Objekt der Klasse zugeordnet wird, die unter seinen  $k$  nächsten Nachbarn am häufigsten vorkommt ( $k$  ist eine positive ganze Zahl, normalerweise klein). Wenn  $k = 1$  ist, dann wird das Objekt einfach der Klasse dieses einen nächsten Nachbarn zugeordnet.



Algorithmen identifizieren & auswählen

# Support vector machine

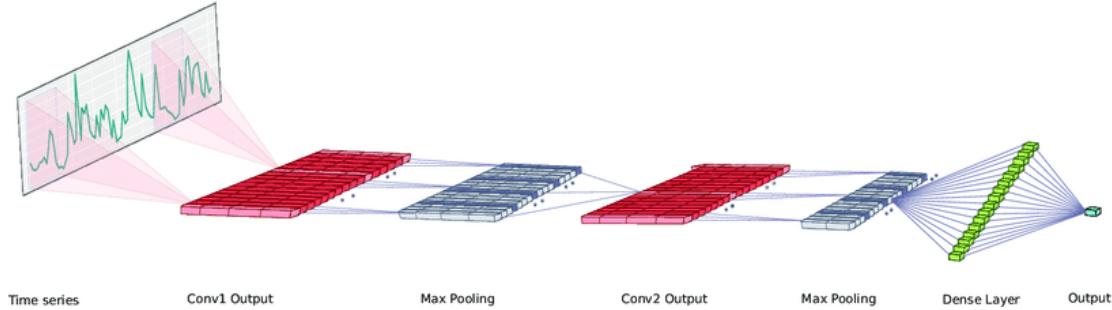


- SVM verwendet eine Hyperebene, um Daten in 2 verschiedene Gruppen zu klassifizieren.
  - SVM ermittelt die beste Hyperebene, die die Daten in 2 Klassen trennt.
1. Bei Anomalien clustert der SVM-Algorithmus das normale Datenverhalten anhand eines Lernbereichs.
  2. Dann identifiziert er anhand des Testbeispiels die Anomalien, die außerhalb des Lernbereichs liegen.

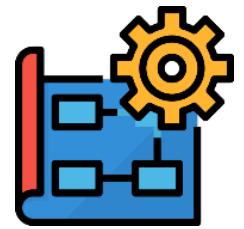


Algorithmen identifizieren & auswählen

# Neural Networks Based



- Traditionelle abstands- und dichte basierte Anomalieerkennungstechniken sind nicht in der Lage, periodische und saisonal bedingte Punktanomalien zu erkennen
- Zum Beispiel ist DeepAnT ist in der Lage Punktanomalien, kontextuelle Anomalien und Unstimmigkeiten in Zeitreihendaten zu erkennen
- Im Allgemeinen werden bei Deep Learning-basierten Ansätzen viele Daten benötigt. In DeepAnT hingegen kann ein Modell auf einem relativ kleinen Datensatz trainiert werden

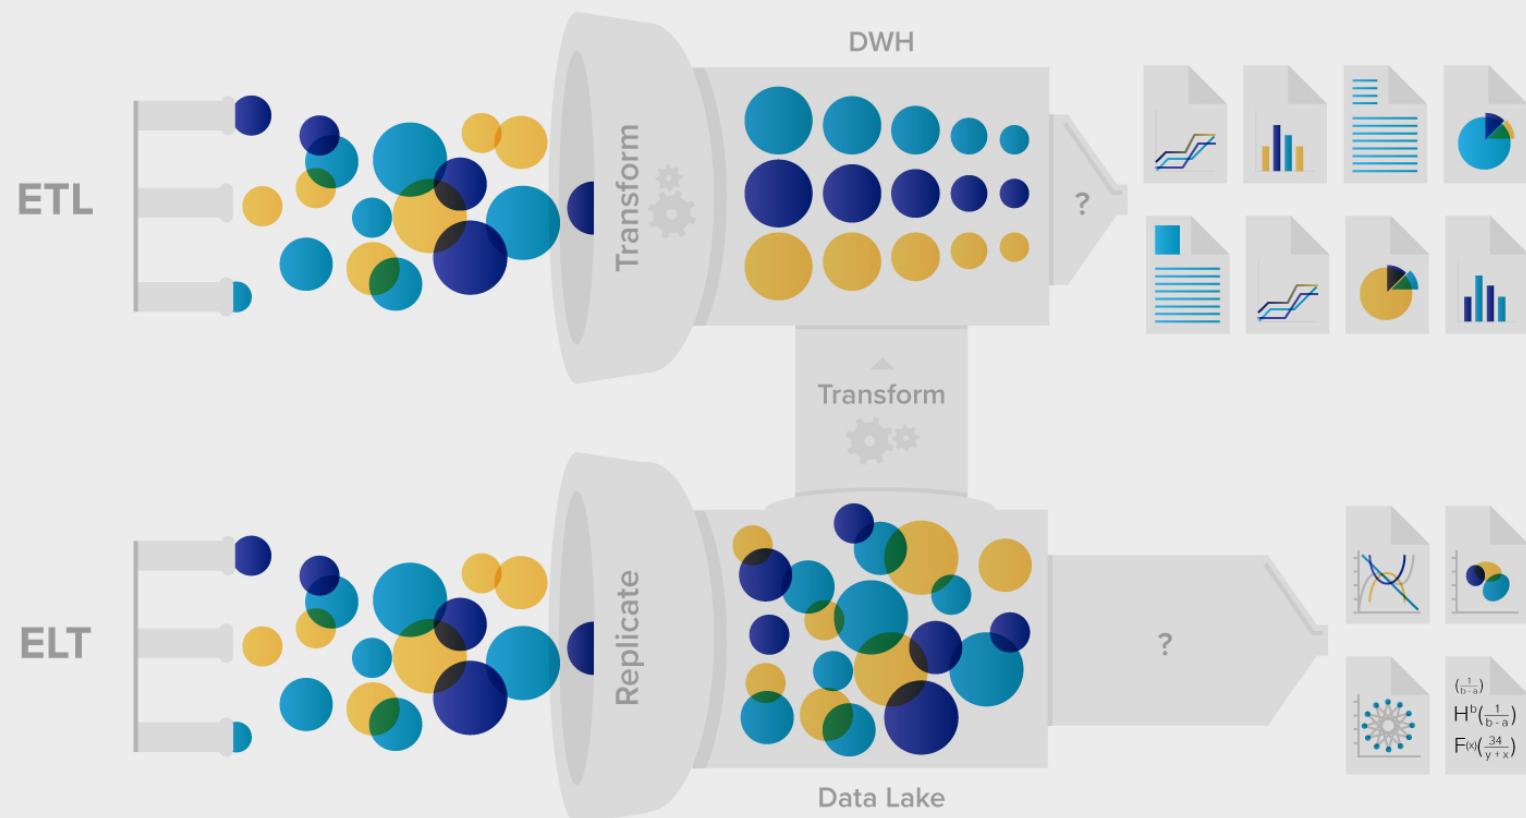


# Daten erfassen



Daten erfassen

# Arten von Datenspeicherung

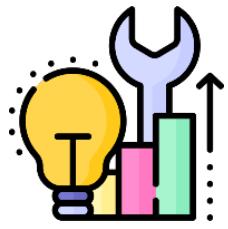




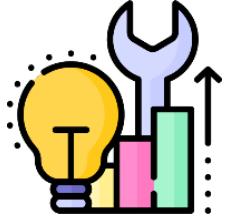
Daten erfassen

# Übersicht von öffentlichen Datensätzen

Dataset Name	Brief description	Preprocessing	Instances	Format	Default Task	Created (updated)	Reference	Creator
Numenta Anomaly Benchmark (NAB)	Data are ordered, timestamped, single-valued metrics. All data files contain anomalies, unless otherwise noted.	None	50+ files	Comma separated values	Anomaly detection	2016 (continually updated)	[425]	Numenta
Skoltech Anomaly Benchmark (SKAB)	single experiment and contains a single anomaly. The dataset represents a multivariate time series collected from the sensors installed on the testbed.	There are two markups for Outlier detection (point anomalies) and Changepoint detection (collective anomalies) problems	30+ files (v0.9)	Comma separated values	Anomaly detection	2020 (continually updated)	[426] [427]	Iurii D. Katser and Vyacheslav O. Kozitsin
On the Evaluation of Unsupervised Outlier Detection: Measures, Datasets, and an Empirical Study	Most data files are adapted from UCI Machine Learning Repository data, some are collected from the literature.	treated for missing values, numerical attributes only, different percentages of anomalies, labels	1000+ files	ARFF	Anomaly detection	2016 (possibly updated with new datasets and/or results)	[428]	Campos et al.



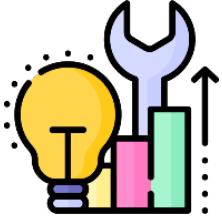
# Daten evaluieren



Daten evaluieren

# Metadaten analysieren

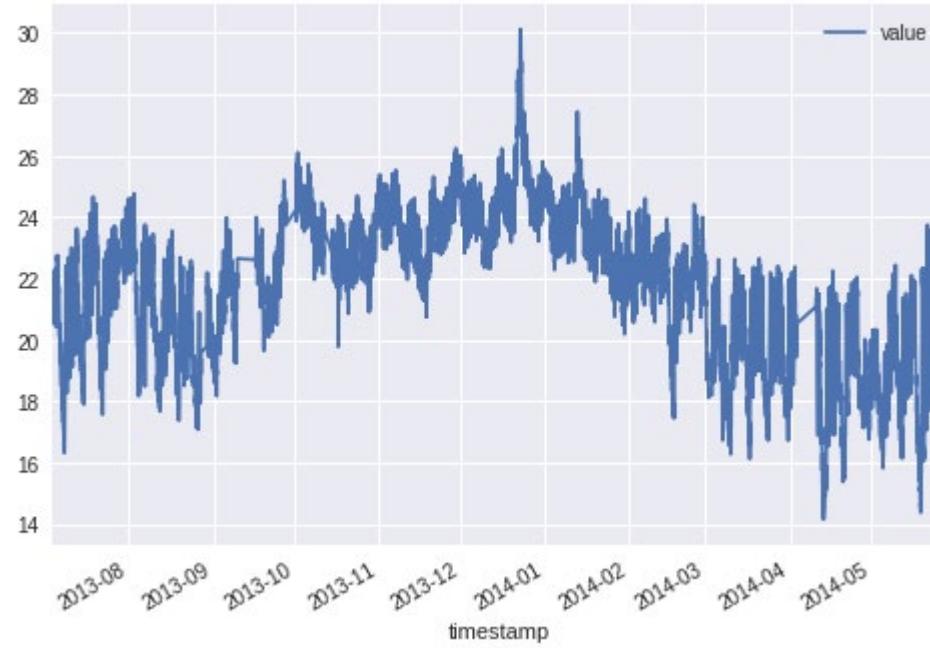
- Serverauslastung: CPU, Network Bytes In, and Disk Read Bytes
  - *ambient\_temperature\_system\_failure*
  - *cpu\_utilization\_asg\_misconfiguration*
  - *ec2\_request\_latency\_system\_failure*
  - *machine\_temperature\_system\_failure*
  - *nyc\_taxi*, *rogue\_agent\_key\_hold*
  - *rogue\_agent\_key\_updown*
- Onlineshop: Klickraten für Online-Werbung: Cost-per-Click (CPC) und Cost per thousand Impressions (CPM)
- Tweets: Anzahl der Erwähnungen für ein bestimmtes Tickersymbol alle 5 Minuten



Daten evaluieren

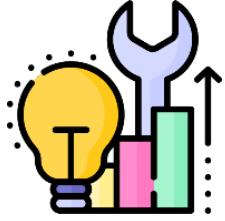
## ambient\_temperature\_system\_failure analysieren

```
1 timestamp,value
2 2013-07-04 00:00:00,69.88083514
3 2013-07-04 01:00:00,71.22022706
4 2013-07-04 02:00:00,70.87780496
5 2013-07-04 03:00:00,68.95939994
6 2013-07-04 04:00:00,69.28355102
7 2013-07-04 05:00:00,70.06096581
8 2013-07-04 06:00:00,69.27976479
9 2013-07-04 07:00:00,69.36960846
10 2013-07-04 08:00:00,69.16671394
11 2013-07-04 09:00:00,68.98608257
12 2013-07-04 10:00:00,69.96506224
13 2013-07-04 11:00:00,70.55619466
14 2013-07-04 12:00:00,70.30750511
15 2013-07-04 13:00:00,70.24625215
16 2013-07-04 14:00:00,69.85490839
17 2013-07-04 15:00:00,71.64329118
18 2013-07-04 16:00:00,71.24565942
19 2013-07-04 17:00:00,70.74509976
20 2013-07-04 18:00:00,71.37329829
```





# Daten aufbereiten

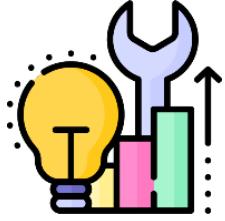


Daten aufbereiten

# Arten der Aufbereitung

**Rohdaten in Erkenntnisse wandeln und Verzerrungen beseitigen:**

- Neuformatierung von Daten
- Durchführung von Datenkorrekturen
- Kombination von Datensätzen zur Anreicherung von Daten
- Standardisierung von Datenformaten
- Entfernen von Ausreißern!



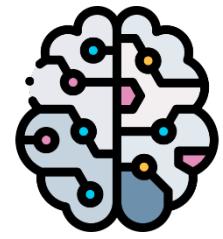
Daten aufbereiten

# Beispiel der Aufbereitung

```
# the hours and if it's night or day (7:00-22:00)
df['hours'] = df['timestamp'].dt.hour
df['daylight'] = ((df['hours'] >= 7) & (df['hours'] <= 22)).astype(int)

# the day of the week (Monday=0, Sunday=6) and if it's a week end day or week day.
df['DayOfTheWeek'] = df['timestamp'].dt.dayofweek
df['WeekDay'] = (df['DayOfTheWeek'] < 5).astype(int)

# time with int to plot easily
df['time_epoch'] = (df['timestamp'].astype(np.int64)/10000000000).astype(np.int64)
```



# Modell trainieren



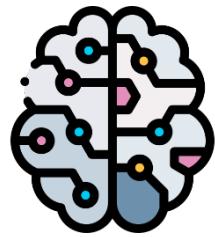
## Feature engineering

# Features reduzieren

```
# Take useful feature and standardize them
data = df[['value', 'hours', 'daylight', 'DayOfTheWeek', 'WeekDay']]
min_max_scaler = preprocessing.StandardScaler()
np_scaled = min_max_scaler.fit_transform(data)
data = pd.DataFrame(np_scaled)

# reduce to 2 importants features
pca = PCA(n_components=2)
data = pca.fit_transform(data)

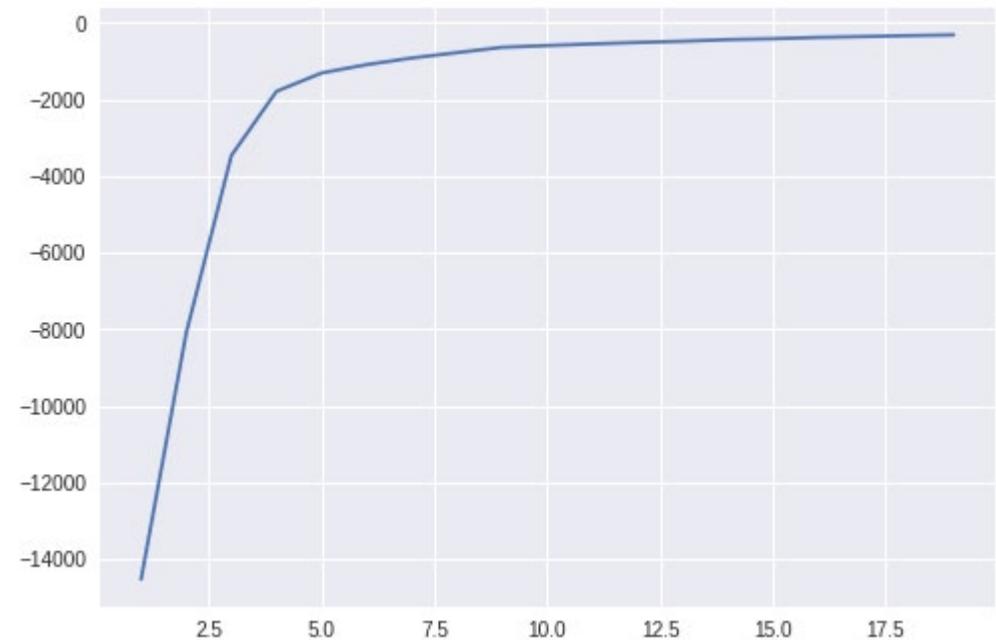
# standardize these 2 new features
min_max_scaler = preprocessing.StandardScaler()
np_scaled = min_max_scaler.fit_transform(data)
data = pd.DataFrame(np_scaled)
```

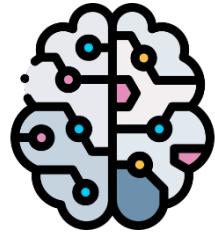


K-mean Modell trainieren

# Anzahl von Zentroiden optimieren

```
# calculate with different number  
of centroids to see the loss plot  
(elbow method)  
n_cluster = range(1, 20)  
kmeans =  
[KMeans(n_clusters=i).fit(data)  
for i in n_cluster]  
scores = [kmeans[i].score(data)  
for i in range(len(kmeans))]  
fig, ax = plt.subplots()  
ax.plot(n_cluster, scores)  
plt.show()
```

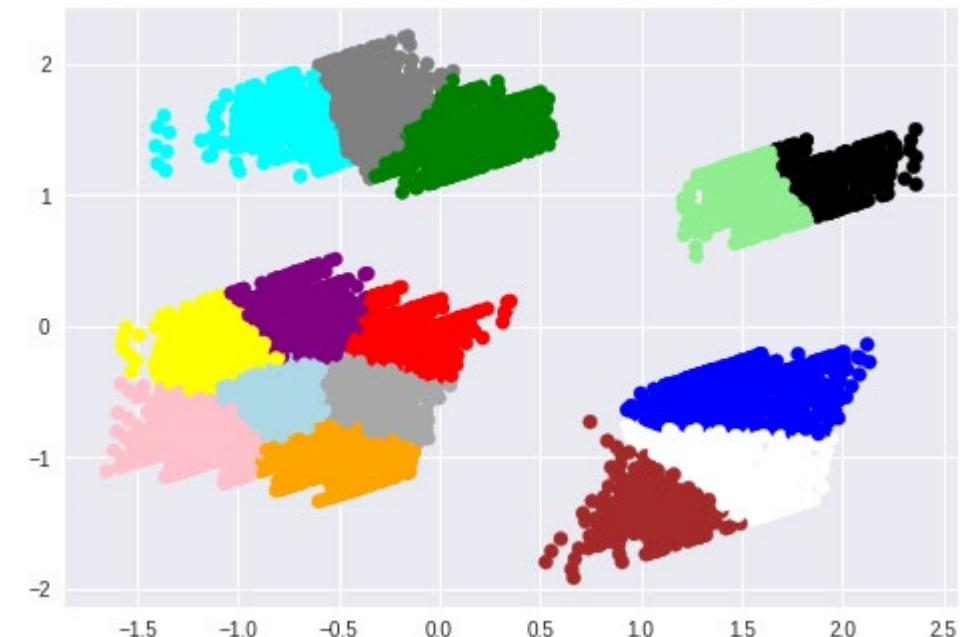


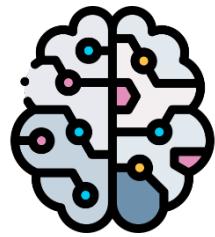


K-mean Modell trainieren

# Visualisierung von Zentroiden

```
#plot the different clusters with the  
2 main features  
fig, ax = plt.subplots()  
colors = {0:'red', 1:'blue',  
2:'green', 3:'pink', 4:'black',  
5:'orange', 6:'cyan', 7:'yellow',  
8:'brown', 9:'purple', 10:'white',  
11: 'grey', 12:'lightblue',  
13:'lightgreen', 14: 'darkgrey'}  
ax.scatter(df['principal_feature1'],  
df['principal_feature2'],  
c=df["cluster"].apply(lambda x:  
colors[x]))  
plt.show()
```





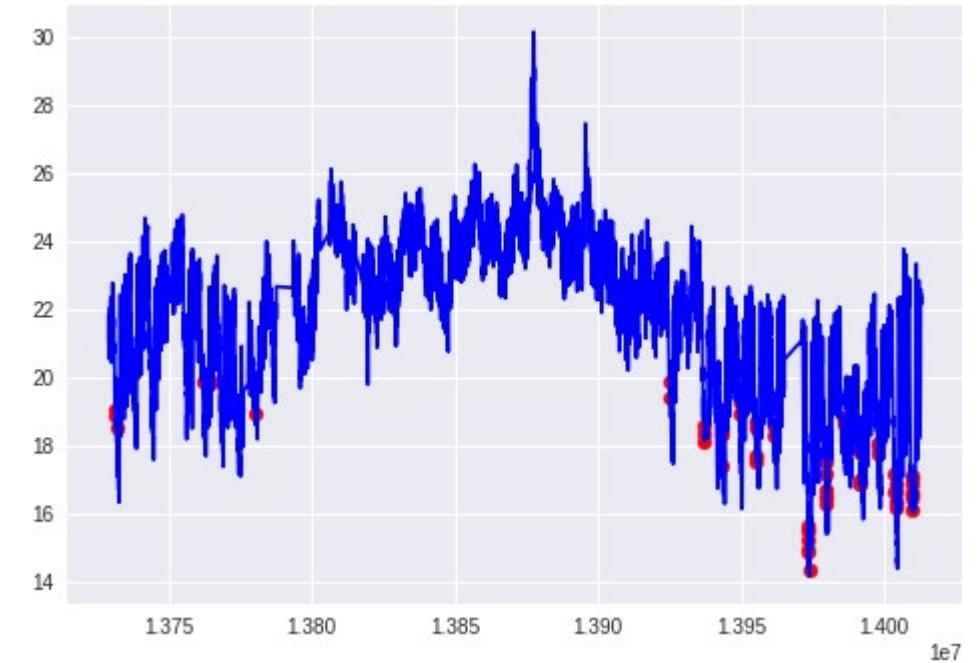
K-mean Modell trainieren

# Anomalie visualisieren

```
# visualisation of anomaly throughout
time (viz 1)
fig, ax = plt.subplots()

a = df.loc[df['anomaly21'] == 1,
['time_epoch', 'value']] #anomaly

ax.plot(df['time_epoch'],
df['value'], color='blue')
ax.scatter(a['time_epoch'], a['value']
, color='red')
plt.show()
```





# Modell evaluieren



Modell evaluieren

# Evaluierungsmetriken

		True condition		Prevalence = $\frac{\sum \text{Condition positive}}{\sum \text{Total population}}$	Accuracy (ACC) = $\frac{\sum \text{True positive} + \sum \text{True negative}}{\sum \text{Total population}}$
Total population	Condition positive	Condition negative			
Predicted condition	Predicted condition positive	<b>True positive</b>	<b>False positive</b> , Type I error	Positive predictive value (PPV), Precision = $\frac{\sum \text{True positive}}{\sum \text{Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\sum \text{False positive}}{\sum \text{Predicted condition positive}}$
	Predicted condition negative	<b>False negative</b> , Type II error	<b>True negative</b>	False omission rate (FOR) = $\frac{\sum \text{False negative}}{\sum \text{Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\sum \text{True negative}}{\sum \text{Predicted condition negative}}$
	True positive rate (TPR), Recall, Sensitivity, probability of detection, Power = $\frac{\sum \text{True positive}}{\sum \text{Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\sum \text{False positive}}{\sum \text{Condition negative}}$	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$	$F_1$ score = $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
	False negative rate (FNR), Miss rate = $\frac{\sum \text{False negative}}{\sum \text{Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\sum \text{True negative}}{\sum \text{Condition negative}}$	Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$		



# Modell bereitstellen



Modell bereitstellen

# Schnittstelle vom Vorhersagen

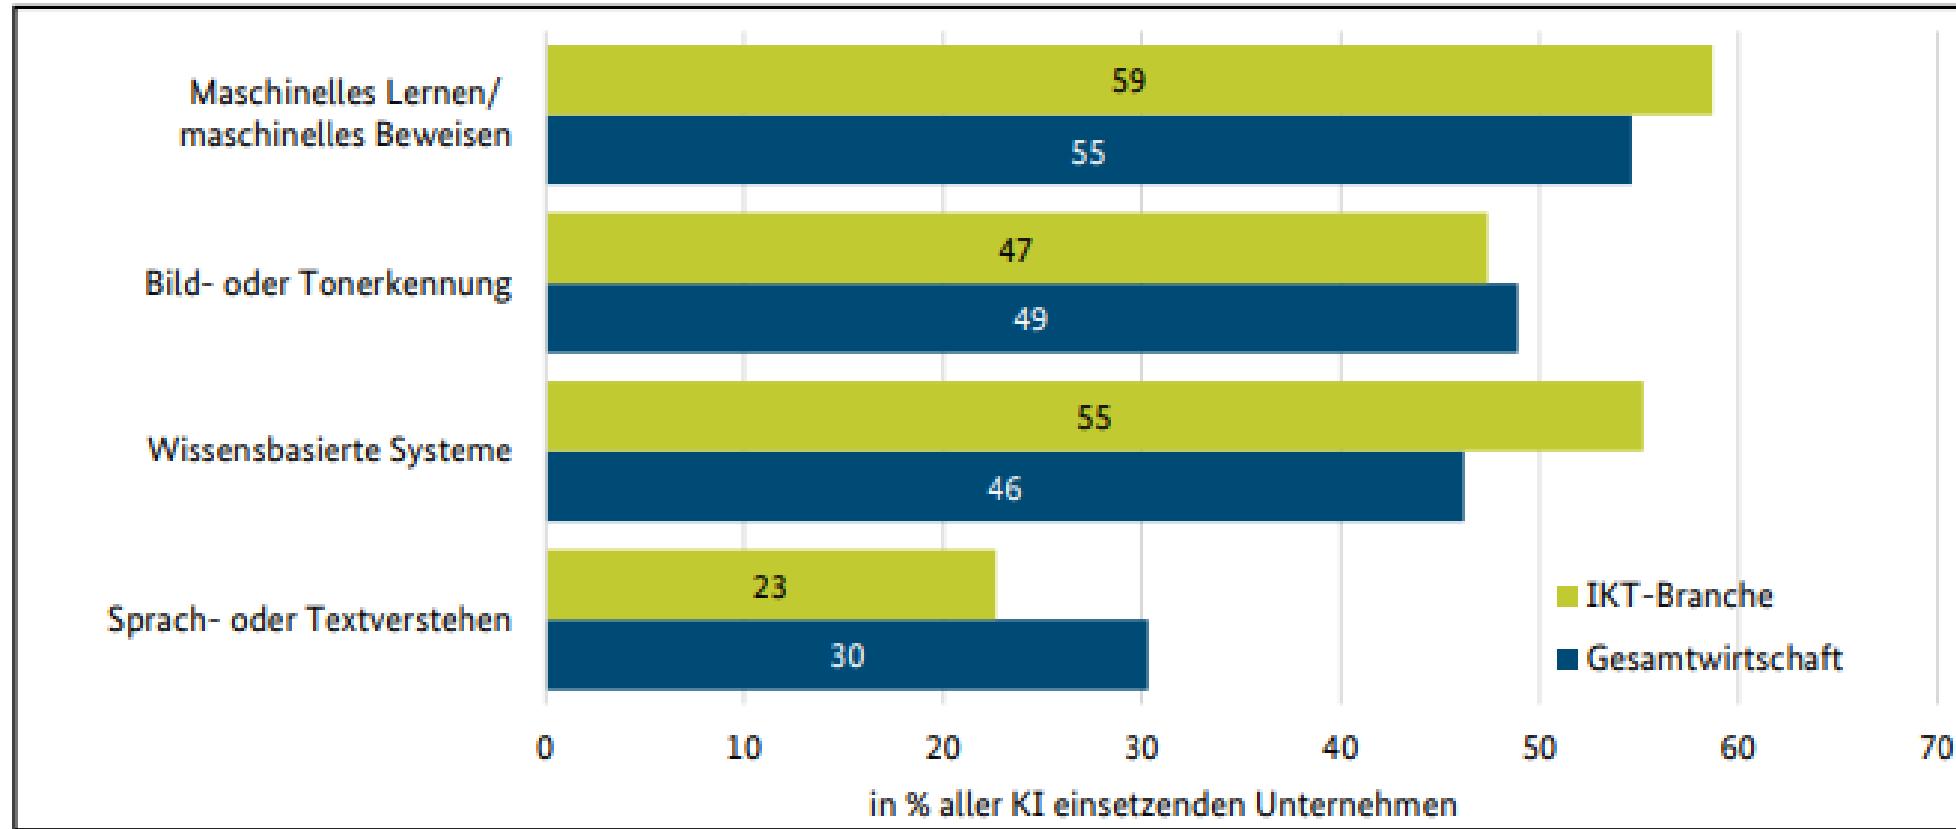
```
@app.route(API_V1 + '/predict', methods=['POST', 'OPTIONS'])
def predict():
    data = request.json
    input = data[input'].strip().replace("\n", "")

    result = model.generate(...)

    return jsonify({'result': result })
```

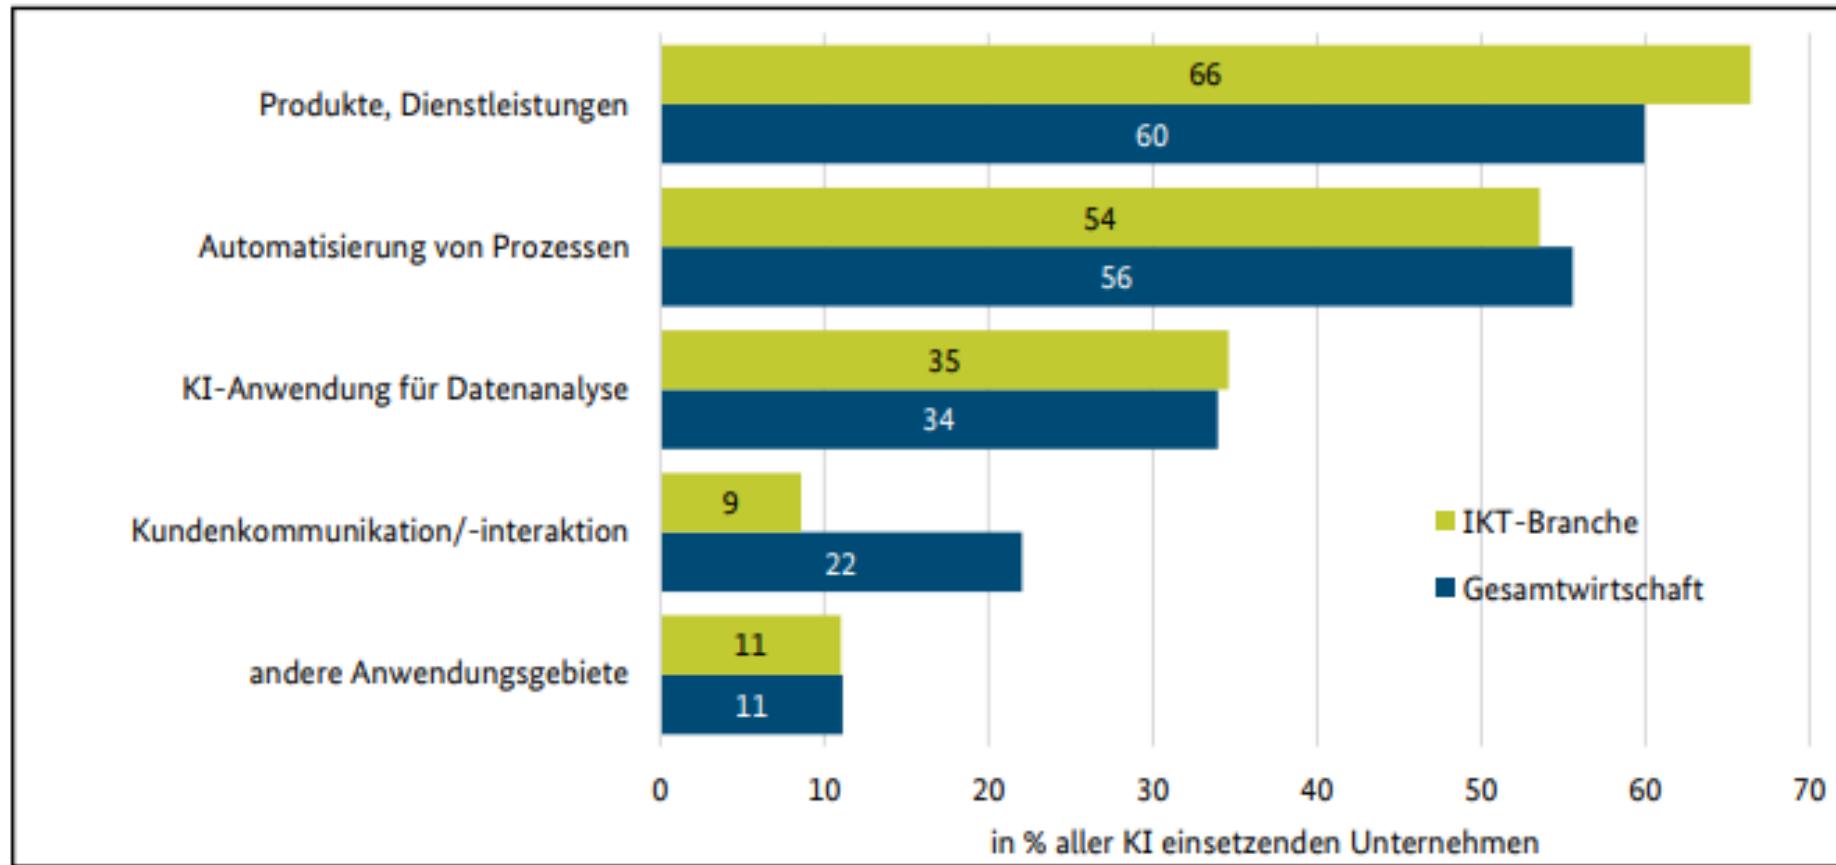
# Einsatz von KI in der Telekommunikations-Branche

# Eingesetzte KI-Verfahren der deutschen IKT-Branche



Quelle: Deutsche Innovationserhebung 2019, Zusatzbefragung KI 2019/2020. Berechnungen des ZEW.

# Eingesetzte KI-Verfahren der deutschen IKT-Branche

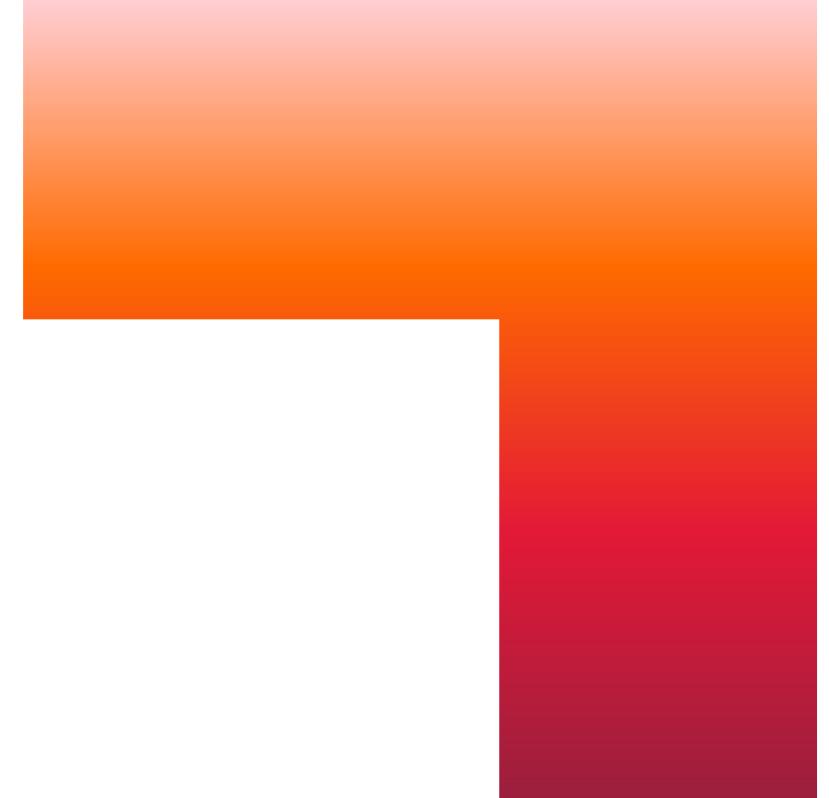


Quelle: Deutsche Innovationserhebung 2019, Zusatzbefragung KI 2019/2020. Berechnungen des ZEW.

# Praxisbeispiele



# CGI Lösungen



- Maschinelles Lernen (Vorhersage)
- Datenverarbeitung in Echtzeit (Analytics)
- Predictive maintenance
- Data lake als Basis für maschinelles Lernen
- Prescriptive analytics

# Produktionsoptimierung für eine Weltklasse-Werft

CGI lieferte eine Lösung, um alle Daten der gesamten Schiffsproduktion in die Plattform zu integrieren. Es wurden Echtzeit-Dashboards sowie detaillierte Berichtslösungen für mehrere Benutzergruppen implementiert.

- Big Data & IoT zur Erfassung und Verarbeitung relevanter Daten
- Es wurden Echtzeit-Dashboards sowie detaillierte Berichtslösungen für mehrere Benutzergruppen implementiert.



---

**Maschinelles Lernen,  
Vorhersage**

Turku in Finnland

# Einsatz von maschinellem Lernen zur Vorhersage von Rissen in Stahl

Eine der größten Herausforderungen bei der Stahlproduktion besteht darin, die Stahlqualität zu verbessern und unnötige Produktionsausschüsse zu reduzieren. Die Risse im Stahl müssen frühzeitig identifiziert werden, um die Qualitätsprobleme auf kosteneffiziente und zeitnahe Weise zu beseitigen oder zu verringern.

- Einsatz von maschinellem Lernen und Advanced Analytics auf relevante Daten, um neue Erkenntnisse zu gewinnen und daraus Wissen zu generieren.
- Vorhersage von Rissen im Stahl mit einer Genauigkeit von 70%



---

**Maschinelles Lernen,  
Vorhersage**

Uddeholm in Schweden

# Vorausschauende Wartung bei großen europäischen Energieunternehmen

CGI arbeitete an der Automatisierung der Inspektion moderner Windturbinenblätter mit Drohnen, Sensoren und KI. Gegenwärtig wird diese Inspektion visuell von Menschen in Klettergurten durchgeführt, die die Klingen abklopfen, was sowohl gefährlich als auch zeitaufwändig ist.

- Luftdrohnen mit mehreren Sensoren, einschließlich thermischer und optischer Kameras, LIDAR
- Das System ist derzeit in der Lage, Risse, Erosion und Blitzeinschläge mit einer Modellgenauigkeit von 95,5% zu erkennen.



---

**Maschinelles Lernen,  
Vorhersage**

Schweden

# Reibungsloser Transport mit modernster Technik

CGI entwickelte ein neues datengesteuertes Geschäftsmodell, sowie eine neue Lösung einen funktionierenden e2e-Piloten bereitstellte und eine Echtzeitansicht des Frachtladeprozesses sowie der Prozesse auf See mit Vorhersagen ermöglichte

- CGI leitete die Implementierung einer Big Data Cloud und On-Ship-Lösungen
- Die Lösung ermöglicht eine um bis zu 10% höhere Schiffsauslastung.



---

International

# Smarte Sensoren für Güterzüge

Mit CGI konnte unser Kunde auf Gleisen montierte Sensoren verwenden, um vorbeifahrende Schienenfahrzeuge auf frühe Anzeichen von Verschleiß zu überwachen und eine vorausschauende Wartung zu ermöglichen. IoT-Sensoren erkennen frühe Anzeichen von Verschleiß, bevor sie den Betrieb stören.

- Die Datenvisualisierung über Webportale und Apps ermöglicht eine vorausschauende Wartung
- Das Ergebnis: höhere Effizienz und Kosteneinsparungen für Güterwagenbesitzer, Eisenbahnunternehmen und Anbieter von Eisenbahninfrastrukturen.



---

**Maschinelles Lernen,  
Vorausschauende Wartung**

Deutschland

# Matching unserer KI Lösungen zur Telekommunikation-Branche

## Data lake

Produktionsoptimierung für Werft

1

Aufbau einer Datenlandschaft

## Machine Learning

Vorhersage von Rissen in Stahl

2

Vorhersage von Sales

## Predictive

Vorausschauende Wartung

3

Wartung im Rechenzentrum

## Real-time ML

Reibungsloser Transport

4

Bestellstrecke optimieren (Upsell)

## Smart sensors

Sensoren für Güterzüge

5

Anomalien bei Servern

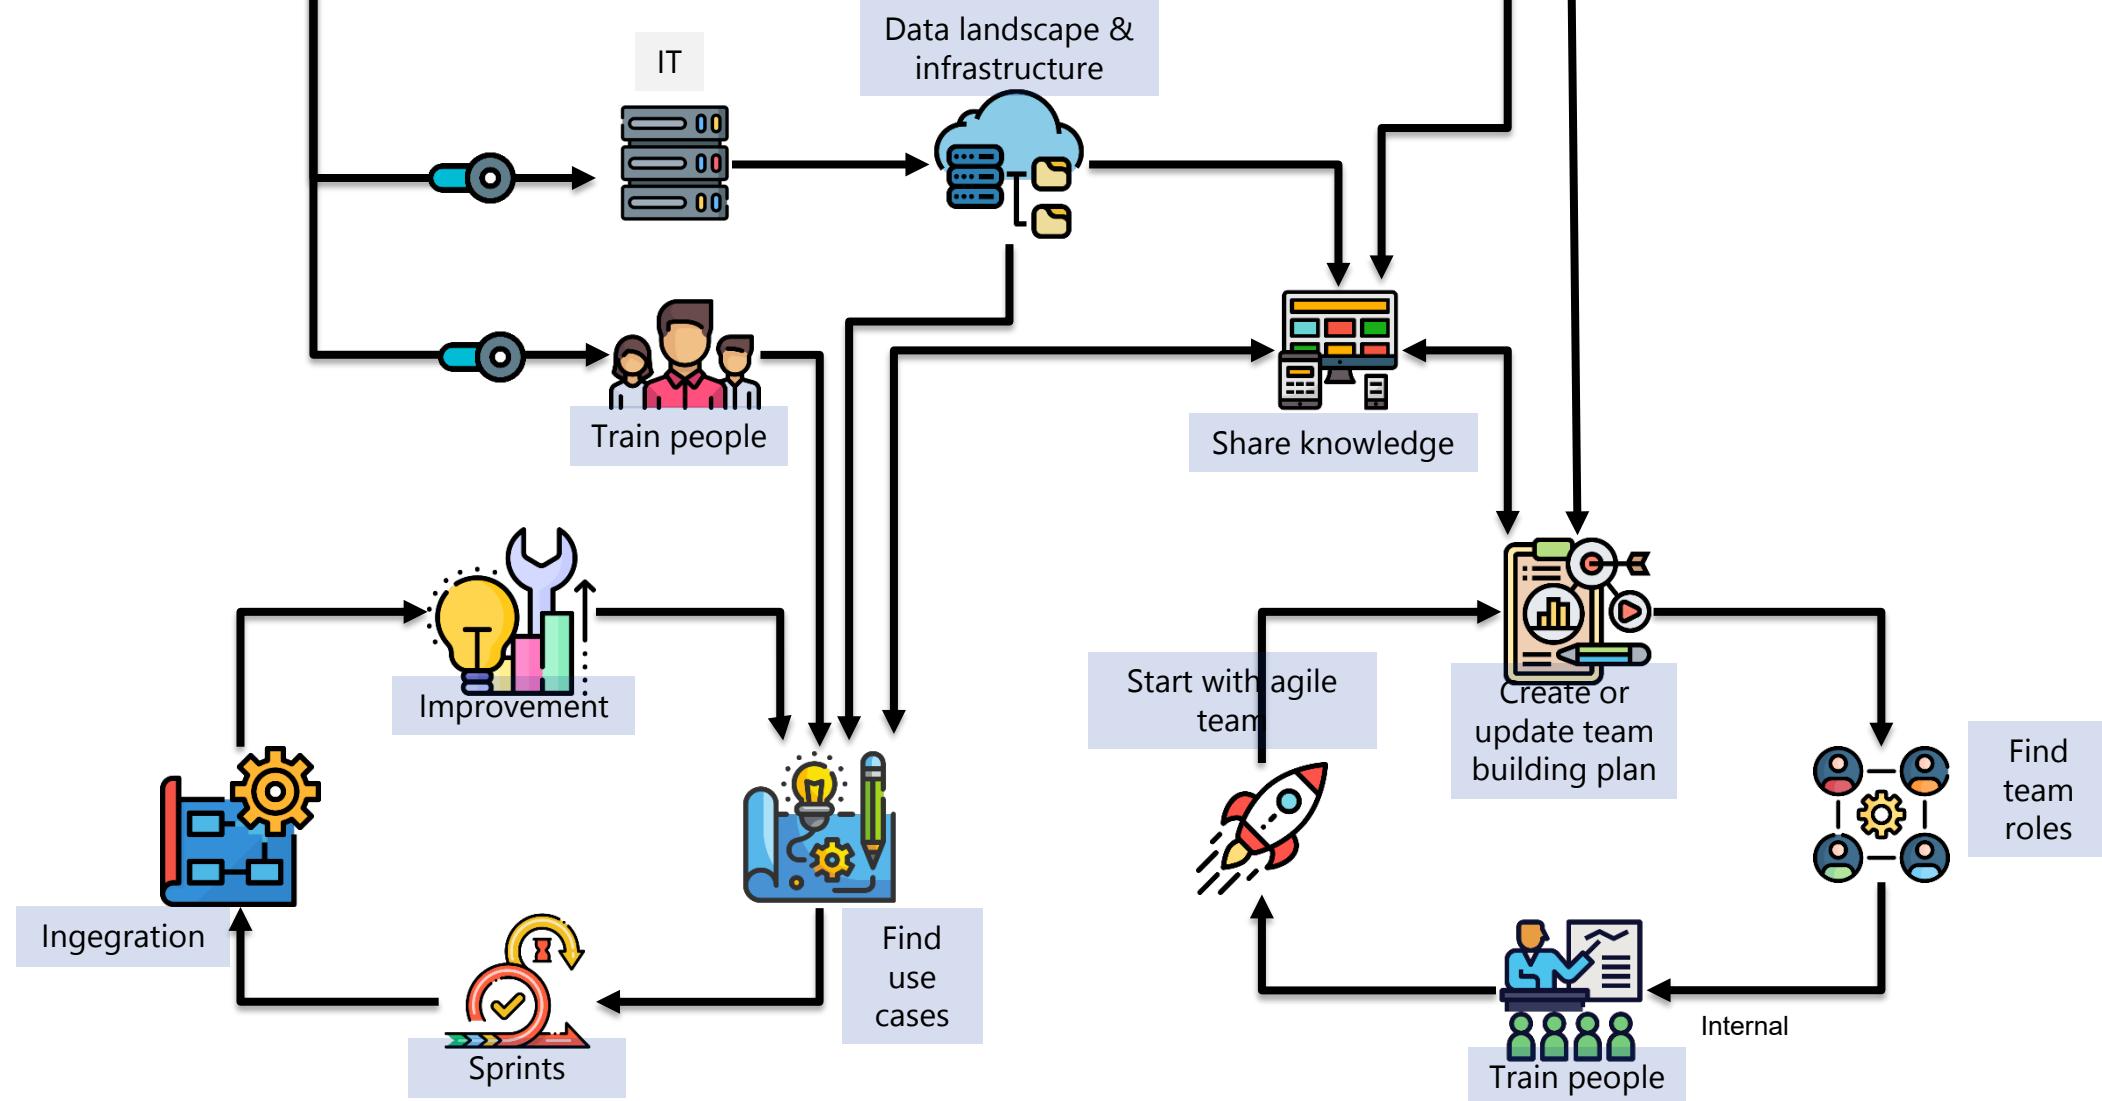
# Standardisierte Prozesse und Arbeitsweisen



# AI COLLABORATION FRAMEWORK



AI COLLABORATION  
FRAMEWORK



# KI Plattform mit Anwendungsfällen



# AI COLLABORATION P L A T F O R M

# vordefinierte KI-Lösungen

AICP Solutions Services Documentation Learn Events

Solutions + Create solution + Submit problem

Reduce errors with predictive maintenance

Show

Better decisions through Knowledge insights

Show

Increase customer loyalty

Show

Saving costs through order picking optimization

Show

Increase speed of research and development

Show

Reduce credit defaults with intelligent credit risk management

Show

Expand product portfolio with new business models

Show

Increase sales with cross selling

Show

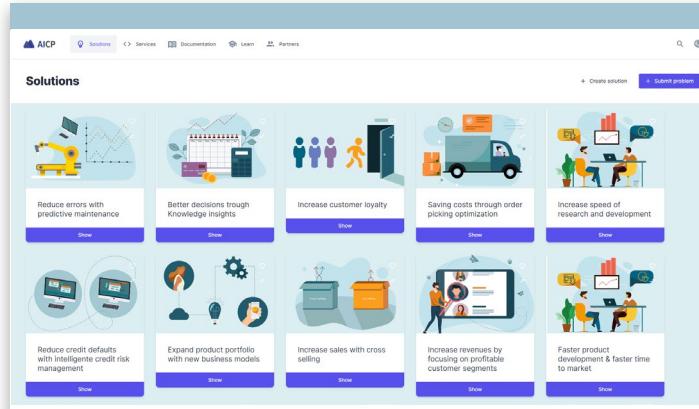
Increase revenues by focusing on profitable customer segments

Show

Faster product development & faster time to market

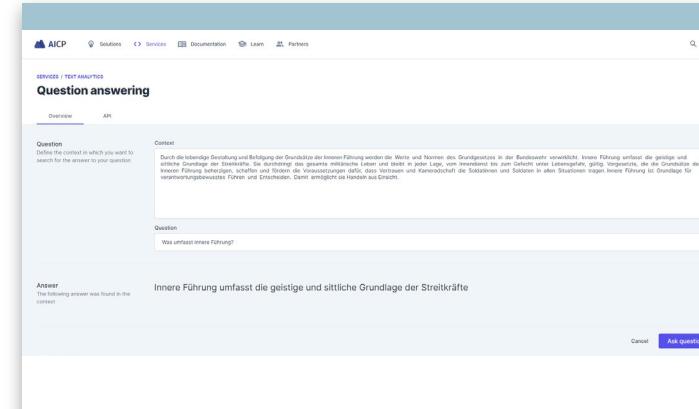
Show

# KI erkunden, ausprobieren und teilen



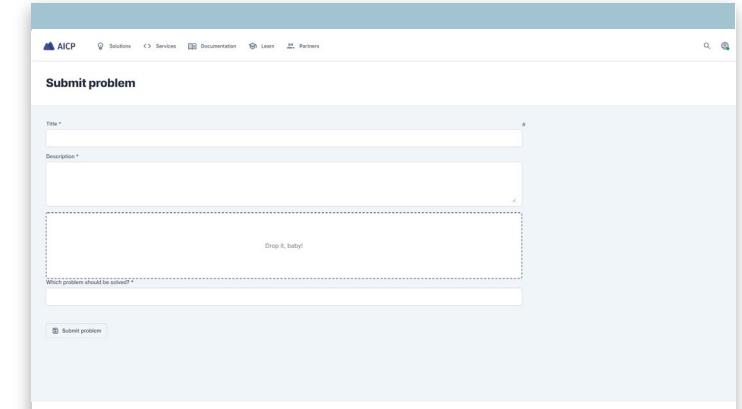
**KI erkunden**

Wir erklären, was KI ist, indem wir eine Sammlung aller KI-bezogenen Lösungen und Services bereitstellen, die in Ihrem Unternehmen eingesetzt werden könnten und am besten zu Ihrem Geschäftsmodell passen.



**KI ausprobieren**

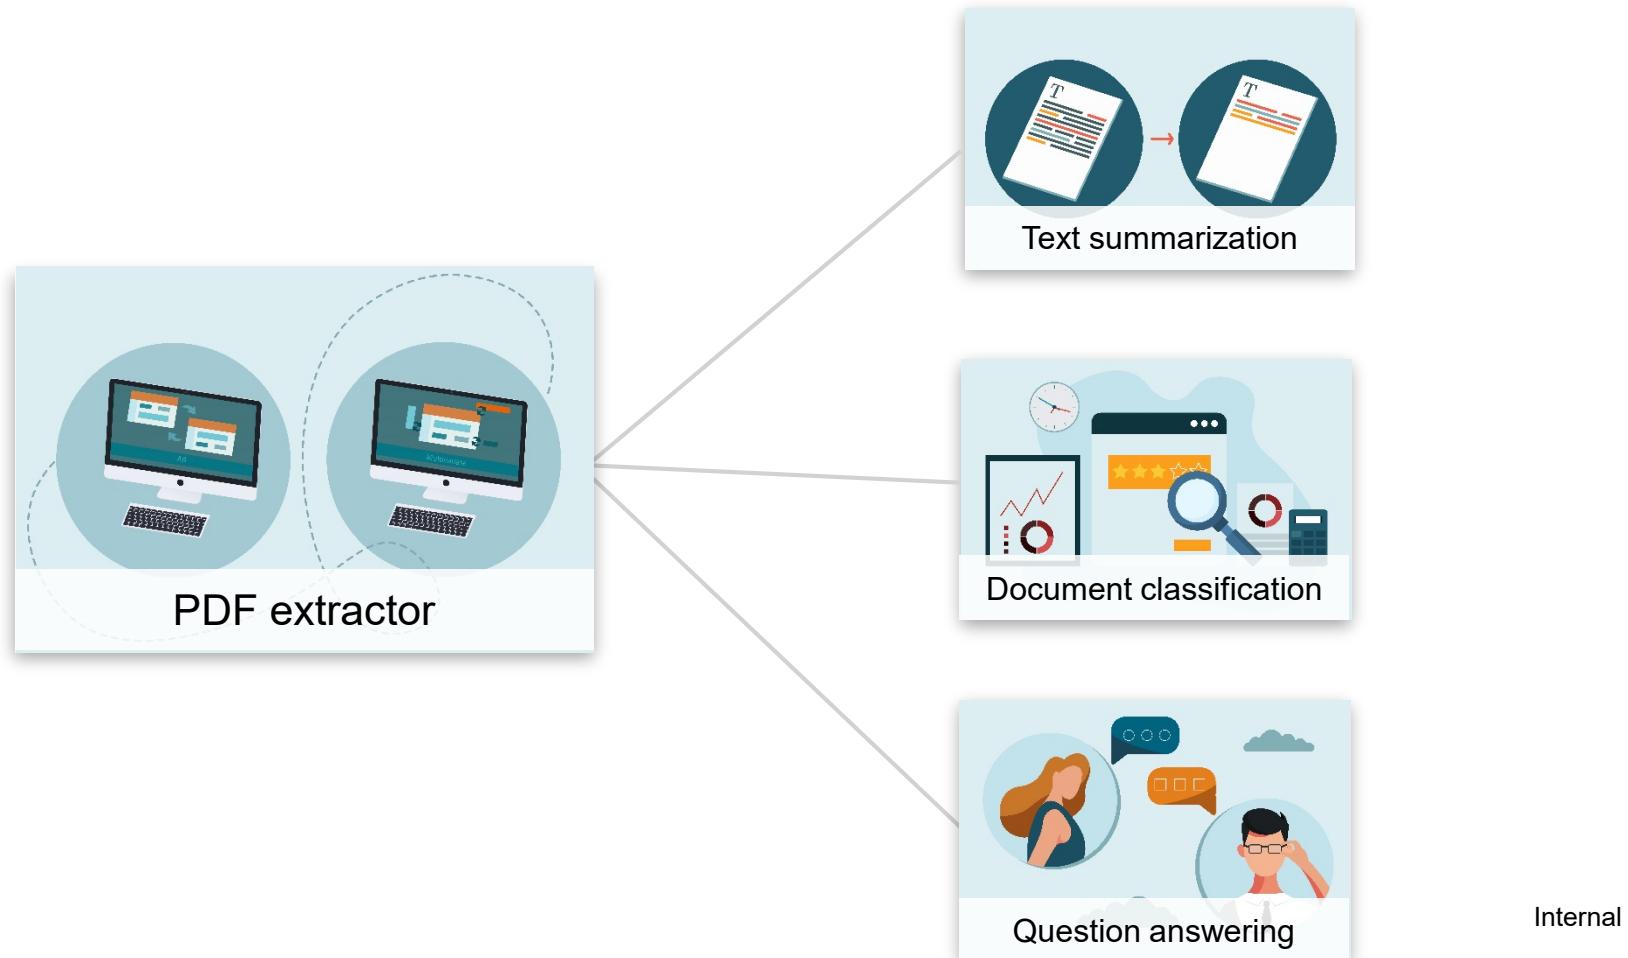
Die Sammlung aller KI-Dienste kann entweder direkt im Browser ausprobiert oder als API integriert werden. Diese Dienste ermöglichen eine einfache Skalierung auf die produktionsreife Umgebung.



**KI teilen**

Lösungen und Dienste können sicher in Ihrem Unternehmen gemeinsam genutzt werden und Sie sparen Geld, indem Sie eigene Dienste und Open-Source-Projekte für Ihre Anwendungsfälle nutzen.

# KI-Lösungen ausführen oder integrieren



# KI-Dienste in der Oberfläche

Innere Führung  
Selbstverständnis und Führungskultur

Änderungsdienst!

Zweck der Regelung:	Festlegung der Konzeption der Inneren Führung als grundlegendes Prinzip des Dienstes in der Bundeswehr. Erläuterung der Inneren Führung als Selbstverständnis aller Soldatinnen und Soldaten sowie als Anspruch an die Menschenführung. Grundlagen und Grundsätze sowie Ziele und Anforderungen der Inneren Führung. Zugrundelegung der Verhaltensnorm und Führungskultur der Bundeswehr. Erläuterung der Gestaltungsfelder der Inneren Führung.
Herausgegeben durch:	Bundesministerium der Verteidigung
Beteiligte Interessenvertretungen:	Hauptpersonalrat und Gesamtvertrauenspersonenausschuss beim Bundesministerium der Verteidigung
Gebilligt durch:	Bundesminister der Verteidigung
Herausgebende Stelle:	BMVg FÜSK II 4
Geltungsbereich:	Geschäftsbereich des Bundesministeriums der Verteidigung
Einstufung:	Offen
Einsatzrelevanz:	Ja
Berichtspflichten:	Nein
Gültig ab:	28.01.2008
Frist zur Überprüfung:	31.12.2015
Version:	1
Überführt:	ZDv 10/1 „Innere Führung“
Aktenzeichen:	35-01-00
Identifikationsnummer:	A.26001.11

## Innere Führung Selbstverständnis und Führungskultur (46 pages)

### Search

führung

### Table of contents

- Titelseite
- Inhaltsverzeichnis
- 1 Selbstverständnis und Anspruch
- 2 Historische Herleitung
- 3 Grundlagen und Grundsätze
  - 3.1 Allgemeines
  - 3.2 Ethische Grundlagen
  - 3.3 Rechtliche Grundlagen
  - 3.4 Politische Grundlagen
  - 3.5 Gesellschaftliche Vorgaben
  - 3.6 Grundsätze der Inneren Führung

# vordefinierte KI-Dienste mit der API



SERVICES / TEXT ANALYTICS

## Question answering

Overview

API

### Question

Define the context in which you want to search for the answer to your question

### Context

Durch die lebendige Gestaltung und Befolgung der Grundsätze der Inneren Führung werden die Werte und Normen des Grundgesetzes in der Bundeswehr verwirklicht. Innere Führung umfasst die geistige und sittliche Grundlage der Streitkräfte. Sie durchdringt das gesamte militärische Leben und bleibt in jeder Lage, vom Innendienst bis zum Gefecht unter Lebensgefahr, gültig. Vorgesetzte, die die Grundsätze der Inneren Führung beherzigen, schaffen und fördern die Voraussetzungen dafür, dass Vertrauen und Kameradschaft die Soldatinnen und Soldaten in allen Situationen tragen. Innere Führung ist Grundlage für verantwortungsbewusstes Führen und Entscheiden. Damit ermöglicht sie Handeln aus Einsicht.

### Question

Was umfasst innere Führung?

### Answer

The following answer was found in the context

Innere Führung umfasst die geistige und sittliche Grundlage der Streitkräfte

Cancel

Ask question